

UNIVERSITÉ [NOM]

ÉCOLE DOCTORALE [NOM]

MASTER 2 EN INFORMATIQUE

Parcours : Intelligence Artificielle et Science des Données

Deep Learning Approaches for Multimodal Biometrics :

Fusion Uncertainty-aware de Visage et d'Empreinte Digitale par Transformer avec Gestion des Modalités Manquantes

Mémoire de fin d'études

Présenté et soutenu publiquement le [DATE]

Présenté par :

[PRÉNOM NOM]

Sous la direction de :

[Prénom NOM DU DIRECTEUR]

[Titre, Affiliation]

Membres du jury :

[Prénom NOM] — [Rôle] — [Affiliation]

[Prénom NOM] — [Rôle] — [Affiliation]

[Prénom NOM] — [Rôle] — [Affiliation]

Année universitaire 2025–2026

Remerciements

Ce mémoire de fin d'études marque l'aboutissement d'un parcours académique riche en découvertes, en défis et en rencontres. Je tiens à exprimer ma profonde gratitude envers toutes les personnes qui ont contribué, de près ou de loin, à la réalisation de ce travail.

Je remercie tout d'abord mon directeur de mémoire, [Prénom NOM DU DIRECTEUR], pour son encadrement exemplaire, sa disponibilité constante et la qualité de ses conseils tout au long de cette année universitaire. Sa rigueur scientifique, sa vision approfondie des architectures d'apprentissage profond et sa patience dans l'explication des concepts les plus complexes ont été des facteurs déterminants dans la réussite de ce projet. Nos nombreuses discussions m'ont permis d'affiner ma pensée critique et de développer une autonomie de recherche que je conserverai tout au long de ma carrière.

Mes remerciements s'adressent également aux membres du jury qui ont accepté d'évaluer ce travail. L'honneur qu'ils me font en consacrant leur temps et leur expertise à la lecture attentive de ce mémoire est profondément apprécié. Leurs retours et recommandations seront précieux pour l'évolution de mes travaux futurs.

Je souhaite exprimer toute ma reconnaissance envers l'équipe pédagogique du Master Intelligence Artificielle et Science des Données pour la qualité exceptionnelle de l'enseignement dispensé au cours de ces deux années. Les cours avancés en deep learning, en traitement d'images et en biométrie m'ont fourni les fondations théoriques et pratiques nécessaires à l'élaboration de cette recherche.

Je tiens à remercier chaleureusement mes camarades de promotion pour les moments de collaboration fructueuse, les sessions de travail communes jusqu'à tard dans la nuit et les échanges enrichissants qui ont animé cette année. Leur soutien moral et intellectuel a été précieux dans les moments de doute.

Enfin, mes pensées les plus affectueuses vont à ma famille pour son soutien inconditionnel tout au long de mes études. Leur confiance en mes capacités et leur patience face aux exigences de ce parcours académique m'ont donné la force de persévérer. Je leur dois beaucoup de ce que je suis devenu aujourd'hui.

À tous, je adresse mes plus sincères remerciements.

[Prénom NOM]

[Ville], [Date]

Résumé

Ce mémoire présente UFM-Transformer (Uncertainty-aware Fusion Multimodal Transformer), une architecture neuronale originale pour la vérification biométrique multimodale associant visage et empreinte digitale. Malgré le déploiement massif des systèmes de fusion visage-empreinte dans les terminaux mobiles et les postes frontaliers, la littérature scientifique peine à concilier quatre exigences opérationnelles cruciales : une fusion représentationnelle riche, la robustesse aux modalités dégradées ou absentes, la calibration probabiliste des scores de similarité, et l’explicabilité des décisions. UFM-Transformer propose une solution unifiée abordant simultanément ces quatre défis. L’architecture repose sur un module d’attention croisée bidirectionnelle dont les logits sont modulés par le produit des scores de qualité des deux modalités, garantissant qu’une source biométrique dégradée contribue proportionnellement moins à la décision. Un token apprenable remplace élégamment toute modalité absente, tandis qu’une procédure de Monte-Carlo Dropout produit des intervalles de confiance calibrés sur chaque décision avec option de rejet. Les poids d’attention croisée fournissent une explication visuelle bimodale inédite, révélant les correspondances entre régions faciales et zones d’empreinte. L’évaluation expérimentale sous dix conditions de dégradation démontre la supériorité d’UFM-Transformer sur cinq méthodes de référence en termes de précision, robustesse et calibration, positionnant cette architecture comme une contribution significative vers des systèmes biométriques autonomes, confiants et interprétables.

Abstract

This thesis presents UFM-Transformer (Uncertainty-aware Fusion Multimodal Transformer), a novel neural architecture for multimodal biometric verification combining face and fingerprint modalities. Despite the widespread deployment of face-fingerprint fusion systems in mobile terminals and border checkpoints, the scientific literature struggles to reconcile four crucial operational requirements: rich representational fusion, robustness to degraded or missing modalities, probabilistic calibration of similarity scores, and decision explainability. UFM-Transformer proposes a unified solution that simultaneously addresses these four challenges. The architecture relies on a bidirectional cross-attention module whose logits are modulated by the product of quality scores from both modalities, ensuring that a degraded biometric source contributes proportionally less to the decision. A learnable token elegantly replaces any missing modality, while a Monte-Carlo Dropout procedure produces calibrated confidence intervals for each decision with a reject option. The cross-attention weights provide a novel bimodal visual explanation, revealing correspondences between facial regions and fingerprint zones. Experimental evaluation under ten degradation conditions demonstrates UFM-Transformer’s superiority over five reference methods in terms of accuracy, robustness, and calibration, positioning this architecture as a significant contribution towards autonomous, confident, and interpretable biometric systems.

Table des matières

Remerciements	1
Résumé	1
Abstract	1
Introduction Générale	8
1 État de l'Art	12
1.1 Architectures de Fusion Profonde pour la Biométrie Multimodale	12
1.1.1 Fusion précoce : concaténation et espaces d'embedding joints	12
1.1.2 Fusion tardive : combinaison au niveau des scores	13
1.1.3 Fusion hybride : architectures multi-étages	14
1.1.4 Synthèse comparative	15
1.2 Mécanismes d'Attention et Transformers pour la Biométrie	15
1.2.1 Self-attention pour la reconnaissance faciale	15
1.2.2 Attention inter-modale : fusion guidée par la qualité	16
1.2.3 Les transformers croisés : de la vision multimodale à la biométrie	17
1.2.4 Gap : absence d'attention croisée visage-empreinte	17
1.3 Robustesse aux Données Dégradées et Modalités Absentes	18
1.3.1 Reconnaissance faciale robuste : occlusion, flou, bruit	18
1.3.2 Reconnaissance d'empreintes dégradées : partielles, latentes, sans contact	18
1.3.3 Estimation de qualité : NFIQ 2.0 et réseaux profonds	19
1.3.4 Gestion des modalités manquantes : un retard critique	19
1.4 Quantification d'Incertitude et Calibration des Scores	20
1.4.1 Incertitude en apprentissage profond : épistémique vs aléatoire	20
1.4.2 Monte-Carlo Dropout et Deep Ensembles	20
1.4.3 Embeddings probabilistes : PFE, DUL et au-delà	21
1.4.4 Calibration : ECE, MCE, temperature scaling	21
1.4.5 Gap : aucun système biométrique multimodal avec quantification d'incertitude	22

1.5	Explicabilité des Systèmes Biométriques Multimodaux	22
1.5.1	Grad-CAM et dérivés pour la reconnaissance faciale	22
1.5.2	Cartes d'attention pour l'importance des minuties d'empreinte . . .	23
1.5.3	Explicabilité multimodale : SHAP, LIME, attention cross-modale .	23
1.5.4	Gap : absence d'explication visuelle bimodale unifiée	24
1.6	Identification du Gap et Positionnement	25
1.6.1	Synthèse des gaps par dimension	25
1.6.2	UFM-Transformer face aux travaux existants	25
1.6.3	Le gap central	26
2	Le Modèle UFM-Transformer	27
2.1	Formulation du Problème	27
2.1.1	Notations et définitions formelles	27
2.1.2	Objectif de vérification ouverte avec qualité variable et modalités partielles	28
2.2	Vue d'Ensemble de l'Architecture	28
2.2.1	Pipeline global : encodeurs $\rightarrow$ projecteurs $\rightarrow$ transformer cross-modal $\rightarrow$ têtes de décision	28
2.2.2	Figure : diagramme d'architecture complet avec flux de données . .	29
2.3	Encodeurs Spécifiques par Modalité	29
2.3.1	Encodeur visage : EfficientNet-B2, pré-entraînement ImageNet, extraction de cartes de caractéristiques	29
2.3.2	Encodeur empreinte : CNN résiduel personnalisé pour les motifs de crêtes	31
2.3.3	Estimateur de qualité : CNN léger par modalité, score dans $[0, 1]$. .	31
2.4	Projecteur Commun et Gestion des Modalités Manquantes	32
2.4.1	Projecteurs denses avec normalisation L2 : projection sur l'hyper-sphère unité	32
2.4.2	Token apprenable de remplacement : $\mathbf{t}_{\text{miss}} \in \mathbb{R}^{256}$ paramètre entraînable	33
2.4.3	Mécanisme de remplacement : masque booléen et encodage positionnel	33
2.5	Module de Fusion par Attention Croisée Modulée par la Qualité	34
2.5.1	Attention croisée bidirectionnelle : requêtes visage $\rightarrow$ clés/valeurs empreinte, et inversement	34
2.5.2	Modulation par qualité : scores d'attention pondérés par $q_f \cdot q_p$. . .	34
2.5.3	Masquage pour modalités absentes : attention nulle vers/depuis modalités manquantes	35
2.5.4	Architecture détaillée : 4 couches, 8 têtes, 256 dimensions	35
2.5.5	Figure : détail du mécanisme d'attention croisée modulée par qualité	36

2.5.6	Algorithme : pseudo-code du <i>forward pass</i>	36
2.6	Tête de Similarité et Tête d'Incertitude	36
2.6.1	Similarité cosinus avec marge additive ArcFace ($m = 0,5$, $s = 30$)	36
2.6.2	Tête d'incertitude : 5 passes avant avec dropout actif	38
2.6.3	Décomposition aléatoire vs épistémique	39
2.6.4	Intervalle de confiance et option de rejet	39
2.7	Mécanismes d'Explicabilité	40
2.7.1	Visualisation des cartes d'attention cross-modale	40
2.7.2	Grad-CAM bimodal : régions faciales et minuties d'empreinte	40
2.7.3	Analyse des cas d'échec par attention	42
2.8	Fonction de Perte et Stratégie d'Entraînement	42
2.8.1	Perte composite : triplet + ArcFace + régularisation d'incertitude	42
2.8.2	Phase 1 : pré-entraînement unimodal (50 époques, ArcFace seul)	43
2.8.3	Phase 2 : fine-tuning joint (100 époques, dropout modalités 30%, perte complète)	43
2.8.4	Optimisation : AdamW, cosine annealing, gradient clipping	44
2.8.5	Algorithme : boucle d'entraînement complète avec deux phases	44
3	Expérimentations et Résultats	46
3.1	Protocole Expérimental	46
3.1.1	Dataset Multimodal Biometrics Dataset	46
3.1.2	Prétraitement et Stratification des Données	47
3.1.3	Augmentations de Données et Simulation de Dégradations	47
3.1.4	Environnement Logiciel et Matériel	48
3.2	Métriques d'Évaluation	48
3.2.1	Métriques de Performance en Vérification Biométrique	48
3.2.2	Métriques de Calibration	49
3.2.3	Métriques d'Efficacité Computationnelle	49
3.3	Résultats Principaux	50
3.3.1	Comparaison avec les Méthodes de Référence	50
3.3.2	Courbes ROC et DET	50
3.3.3	Distribution des Scores de Similarité	51
3.4	Analyse de Robustesse	53
3.4.1	Résultats sous Dégradations Contrôlées	53
3.4.2	Mode Unimodal Forcé	53
3.5	Calibration de l'Incertitude	54
3.5.1	Diagramme de Fiabilité	54
3.5.2	ECE et MCE Quantitatifs	54
3.5.3	Performances avec Option de Rejet	56

3.6	Étude d'Ablation	57
3.6.1	Contribution de Chaque Composant	57
3.7	Résultats d'Explicabilité	58
3.8	Efficacité Computationnelle	59
4	Discussion et Perspectives	61
4.1	Interprétation des Résultats	61
4.1.1	Supériorité sur les baselines : le rôle synergique de chaque composant	61
4.1.2	L'incertitude comme indicateur fiable de confiance	62
4.1.3	L'explicabilité comme outil de diagnostic	63
4.2	Limites	63
4.2.1	Échelle du corpus : le seuil des 100 sujets	63
4.2.2	Modalités restreintes : la paire visage-empreinte	64
4.2.3	Coût computationnel du MC-Dropout	64
4.3	Perspectives	64
4.3.1	Extension multimodale : iris, voix, paume	64
4.3.2	Distillation de connaissances pour le déploiement <i>edge</i>	65
4.3.3	Apprentissage fédéré préservant la confidentialité	65
4.3.4	Prédiction conforme pour des garanties théoriques	66
	Conclusion Générale	67
	A Code Source et Reproductibilité	77
	B Détail des Hyperparamètres	78
	C Résultats Complémentaires	80
C.1	Matrice de Confusion Détaillée	80
C.2	Courbes d'Apprentissage	80
C.3	Visualisations Supplémentaires d'Explicabilité	80

Table des figures

1.1	Illustration schématique du gap d’explicabilité bimodale : (a) explication unimodale visage par CorrRISE, (b) explication unimodale empreinte par attention aux minuties, (c) l’explication bimodale unifiée que UFM-Transformer fournit via les poids d’attention croisée. Aucun travail existant ne produit (c).	24
2.1	Architecture complète de l’UFM-Transformer. Les dimensions tensorielles sont indiquées à chaque étape. Les flèches en trait plein représentent les flux de données ; les flèches en pointillés représentent les scores de qualité modulant l’attention. Le symbole $\otimes$ dénote la modulation multiplicative des logits d’attention par le produit $q_f \cdot q_p$	30
2.2	Détail du mécanisme d’attention croisée modulée par qualité pour une couche. La direction visage $\rightarrow$ empreinte est illustrée ; la direction inverse est symétrique. Le bloc de modulation multiplie les logits d’attention par $\log(q_f \cdot q_p)$ avant le softmax. Le masque booléen m force les poids à zéro pour les modalités absentes.	37
2.3	Visualisation bimodale de l’explicabilité. À gauche : carte Grad-CAM superposée à l’image faciale, avec les régions chaudes indiquant les zones contributives. Au centre : carte d’attention de l’empreinte alignée sur les minuties. À droite : graphe bipartite des poids d’attention cross-modale entre les deux représentations.	41
3.1	(Gauche) Courbes ROC comparatives. UFM-Transformer domine dans la région à faible FAR. (Droite) Courbes DET ; les axes logarithmiques révèlent l’avantage accru dans le régime de sécurité élevée ($FAR < 0.1\%$). . .	51
3.2	Diagrammes en violon des scores de similarité UFM-Transformer. (Haut) Scores intra-classe (paires positives). (Bas) Scores inter-classe (paires négatives). La séparation des distributions conditionne l’EER et le TAR opérationnel.	52

3.3	Diagramme de fiabilité (reliability diagram). L'axe des abscisses indique la confiance moyenne prédite par le modèle dans chaque bac ; l'axe des ordonnées la précision empirique. La diagonale pleine représente la calibration parfaite. L'histogramme en fond indique la fréquence des prédictions par niveau de confiance.	55
3.4	(Gauche) EER en fonction du taux de rejet pour différents seuils d'incertitude. La courbe décroissante montre que le rejet des échantillons incertains améliore la qualité des décisions automatiques. (Droite) Taux de FNMR et FMR après rejet, illustrant la symétrie du gain.	56
C.1	Exemples de visualisations d'explicabilité pour des paires positives. (Haut) Paire facile : forte similarité, attention focalisée. (Bas) Paire difficile : faible similarité, attention dispersée, forte incertitude.	81
C.2	Exemples de visualisations d'explicabilité pour des paires négatives. (Haut) Paire facile : faible similarité, attention différenciée. (Bas) Paire difficile : ressemblance fortuite, attention confuse, forte incertitude prédite.	82

Liste des tableaux

1.1	Comparaison des stratégies de fusion profonde pour la biométrie multimodale.	15
1.2	Synthèse des gaps scientifiques par dimension de l'état de l'art.	25
1.3	Comparatif d'UFM-Transformer avec les travaux les plus proches de l'état de l'art selon huit dimensions. ✓ = satisfait pleinement, (○) = satisfait partiellement, × = non satisfait.	25
2.1	Hyperparamètres du module de fusion par attention croisée	36
2.2	Hyperparamètres de la phase 2 d'entraînement (fine-tuning joint)	44
3.1	Comparaison des performances de vérification biométrique. TAR rapporté à deux seuils opérationnels (FAR = 0.1% et FAR = 1%). Meilleurs résultats en gras.	50
3.2	EER (%) sous dix conditions de dégradation. Best et Second-best en gras et italique. U = UFM-Transformer, C = Concaténation, A = Cross-Attention, D = DenseNet-Fusion, V = ResNet-18 visage, E = ResNet-18 empreinte.	53
3.3	Métriques de calibration : ECE et MCE (%) sur l'ensemble de test. Bacs de calibration : $M = 15$. Meilleur résultat en gras.	55
3.4	Étude d'ablation : contribution de chaque composant de l'architecture UFM-Transformer. Écart relatif à la configuration complète.	57
3.5	Comparaison de l'efficacité computationnelle. Inférence mesurée sur GPU NVIDIA A100, batch size = 1, moyenne sur 1000 paires.	59
B.1	Hyperparamètres complets de l'UFM-Transformer	79

Introduction Générale

L’identité numérique constitue aujourd’hui le socle sur lequel reposent l’ensemble des transactions critiques de la société contemporaine — accès bancaire, franchissement de frontière, télésoin, administration en ligne. Face à la prolifération des attaques par usurpation, la biométrie offre une promesse fondamentale : lier l’identité déclarée à un trait physiologique inaliénable. Parmi les modalités déployées à grande échelle, le visage et l’empreinte digitale dominent le paysage opérationnel par leur complémentarité naturelle : le visage capture la géométrie craniofaciale dans des conditions de distance, tandis que l’empreinte digitale offre une richesse de détail locale inégalée au contact. Leur combinaison, désormais systématique dans les terminaux mobiles et les postes frontières, constitue l’un des paradigmes de fusion multimodale les plus étudiés de la dernière décennie [34, 54].

Pourtant, cette complémentarité ne se traduit pas automatiquement en robustesse. Les systèmes contemporains de fusion visage-empreinte peinent à maintenir leurs performances dès que les conditions de capture s’éloignent du protocole contrôlé : éclairage défavorable, flou de mouvement, empreinte humide ou partiellement occluse. La raison en est profondément structurelle. La plupart des architectures de fusion opèrent par concaténation d’*embeddings* ou combinaison de scores [71, 72], sans mécanisme explicite pour moduler l’influence d’une modalité dégradée ni pour gérer l’absence contingente d’un capteur. Lorsqu’une modalité s’altère, ses caractéristiques corrompues se propagent dans la représentation fusionnée, entraînant une dégradation parfois brutale de la performance globale.

L’avènement des réseaux profonds a transformé ce paysage sans pour autant résoudre ses contradictions fondamentales. Les convolutions neuronales profondes (CNN) ont porté la précision de la reconnaissance faciale à des niveaux supérieurs à la perception humaine sur des benchmarks contrôlés [15]. Les *Vision Transformers* (ViT), initialement conçus pour la classification générique d’images, ont été adaptés avec succès à la biométrie faciale [13, 83] et papillaire [24, 59], exploitant leur capacité à modéliser les dépendances globales entre patches d’image. L’attention croisée entre modalités distinctes, héritière des architectures multimodales de vision [53], a montré sa supériorité empirique sur les stratégies de fusion conventionnelles [?] : sur la reconnaissance audio-visuelle de personnes, l’attention croisée atteint un EER de 2,387 contre 2,412 (*self-attention*), 2,489 (concaténation) et 2,521 (fusion *score-level*).

Cette hiérarchie établit la pertinence du paradigme transformer pour la biométrie multimodale, mais soulève simultanément quatre défis que la littérature n’a pas encore résolus conjointement.

Premier défi : l’alignement sous dégradation. Lorsqu’un visage est flouté ou qu’une empreinte est partielle, les représentations extraites par les encodeurs profonds perdent leur structure discriminante. Les fonctions de perte adaptatives à la qualité [38,52] et les estimateurs FIQA [8] ont amélioré la reconnaissance faciale sous dégradation, mais ces avancées n’ont pas été intégrées dans les mécanismes d’attention croisée entre modalités biométriques distinctes. La question demeure : comment moduler l’attention entre visage et empreinte de sorte qu’une modalité dégradée contribue proportionnellement moins à la décision fusionnée ?

Deuxième défi : les modalités manquantes. En conditions opérationnelles, un capteur peut être indisponible : lecteur d’empreinte défaillant, caméra obstruée, refus de coopération de l’utilisateur. La biométrie multimodale n’a pas encore adopté les solutions sophistiquées développées en imagerie médicale [48,63,84], où les *proxy tokens* et le *prompt tuning* gèrent nativement toute sous-combinaison de modalités. Ma *et al.* [47] ont établi de manière frappante que les transformers multimodaux ne sont même pas naturellement robustes aux modalités manquantes — ils peuvent être surpassés par des modèles unimodaux. Ce retard de plus de cinq ans constitue une lacune critique.

Troisième défi : l’absence d’incertitude calibrée. Les systèmes biométriques produisent des scores de similarité déterministes, sans intervalle de confiance ni option de rejet. Or la prédiction d’un score élevé entre deux échantillons dégradés peut être une illusion statistique. Les *Probabilistic Face Embeddings* (PFE) [69] et l’apprentissage conjoint de l’incertitude (DUL) [?] ont introduit la modélisation probabiliste des embeddings pour la reconnaissance faciale unimodale. Le Monte-Carlo Dropout [20] et les *Deep Ensembles* [18] offrent des cadres généraux pour la quantification de l’incertitude. Pourtant, aucun système biométrique multimodal ne propage l’incertitude de chaque modalité à travers le processus de fusion pour produire des scores calibrés avec option de rejet.

Quatrième défi : l’explicabilité bimodale. La confiance des utilisateurs et des opérateurs dans une décision biométrique repose sur la capacité à expliquer cette décision. Les méthodes de visualisation par gradient [?, 46] produisent des cartes de saillance unimodales de grande qualité. SHAP et LIME [66] quantifient les contributions modales mais de manière *post-hoc*. Aucun travail publié ne fournit d’explications visuelles unifiées mettant simultanément en évidence les régions faciales *et* les points minuties d’empreinte ayant conjointement déterminé une décision bimodale.

Ces quatre défis ne sont pas isolés : ils forment un ensemble interconnecté que nous qualifions de « problème des îlots modaux ». Chaque communauté scientifique traite un aspect sans intégrer les autres. Les chercheurs en fusion précoce optimisent la concaténation de caractéristiques [72] ; ceux en fusion tardive affinent les règles de combinaison de

scores [54]; les communautés d’incertitude [?, 69] et d’explicabilité [46, 55] évoluent séparément. AuthFormer [82] atteint l’attention croisée avec adaptation modale mais ignore l’incertitude, les modalités manquantes et l’explicabilité bimodale. QME [87] gère la qualité et les modalités manquantes mais opère au niveau des scores et ne quantifie pas l’incertitude. PFE/DUL [?, 69] fournissent des embeddings probabilistes calibrés mais pour la reconnaissance faciale unimodale uniquement. À travers plus de 150 travaux examinés, aucun ne satisfait plus de deux des quatre exigences simultanément.

Ce mémoire propose une architecture originale — UFM-Transformer (*Uncertainty-aware Fusion Multimodal Transformer*) — qui intègre ces quatre capacités dans un seul framework différentiable. Cinq contributions principales structurent ce travail.

Contribution 1 : UFM-Transformer constitue la première architecture unifiée abordant simultanément les quatre défis identifiés. Contrairement aux approches fragmentaires de l’état de l’art, elle rend chaque composante — les poids d’attention, les estimations d’incertitude, les cartes d’explication — des sous-produits naturels d’un même mécanisme d’attention croisée probabiliste. Les poids d’attention modulent la fusion tout en fournissant l’explicabilité; les variances de features, propagées par la loi de la variance totale, quantifient l’incertitude tout en informant la modulation par qualité.

Contribution 2 : Un module de fusion par attention croisée bidirectionnelle modulée par la qualité, avec gestion native des modalités manquantes par *token* apprenable. Les logits d’attention sont pondérés par le produit des scores de qualité $q_f \cdot q_p$, garantissant qu’une modalité dégradée contribue proportionnellement moins au résultat. Un *token* apprenable $\mathbf{t}_{\text{miss}} \in \mathbb{R}^{256}$, inspiré des *Cross-Modal Proxy Tokens* [63], remplace la représentation d’une modalité absente sans nécessiter de branche architecturale distincte. Le mécanisme de *modality dropout* [56], appliqué avec une probabilité de 30% durant l’entraînement, prépare l’architecture à fonctionner avec toute sous-combinaison de modalités.

Contribution 3 : Une procédure de calibration probabiliste des scores de similarité par Monte-Carlo Dropout [20], produisant des intervalles de confiance associés à chaque décision de vérification. Cinq passes avant avec *dropout* actif décomposent l’incertitude totale en composantes aléatoire et épistémique suivant la taxonomie de Kendall & Gal [37]. Un mécanisme d’option de rejet, calibré sur l’ensemble de validation, permet au système d’abstenir de décider lorsque la confiance est insuffisante — une fonctionnalité inédite en fusion biométrique multimodale.

Contribution 4 : Un mécanisme d’explicabilité bimodale exploitant la dualité fonctionnelle des poids d’attention croisée. Ces poids servent simultanément à moduler la fusion et à révéler quelles régions faciales correspondent à quelles zones d’empreinte pour l’appariement identitaire. Combinés à Grad-CAM [?], ils produisent des explications visuelles unifiées — régions faciales *et* minuties d’empreinte — qui n’existaient pas dans la littérature biométrique.

Contribution 5 : Une validation expérimentale extensive comparant UFM-Transformer à cinq baselines représentatives (fusion précoce, fusion tardive, fusion hybride, transformer *self-attention*, fusion par *gating*) sous dix conditions de dégradation différentes (occlusion, flou, bruit, compression JPEG, sous-échantillonnage, et leurs combinaisons). L’analyse d’ablation quantifie la contribution marginale de chaque composante architecturale.

Ce mémoire s’organise en quatre chapitres. Le Chapitre 1 procède à une revue systématique de la littérature selon cinq thèmes : architectures de fusion profonde, mécanismes d’attention et transformers, robustesse aux données dégradées et modalités absentes, quantification d’incertitude, et explicabilité. Il identifie de manière circonstanciée le gap scientifique que UFM-Transformer comble. Le Chapitre 2 développe formellement l’architecture : notations, pipeline global, encodeurs modali-spécifiques, projecteurs, module d’attention croisée modulée, tête de similarité, tête d’incertitude, mécanismes d’explicabilité, fonction de perte composite et stratégie d’entraînement en deux phases. Le Chapitre 3 présente le protocole expérimental, les métriques d’évaluation, les résultats principaux, l’analyse de robustesse sous dégradation, la calibration de l’incertitude, l’étude d’ablation et les résultats d’explicabilité. Le Chapitre 4 interprète les résultats, discute les limites de l’étude et propose des perspectives de recherche.

Chapitre 1

État de l’Art

La biométrie multimodale, et spécifiquement la fusion du visage et de l’empreinte digitale, constitue l’un des dispositifs d’identification les plus déployés à l’échelle planétaire — des postes frontières aux terminaux mobiles. Pourtant, les systèmes contemporains peinent à concilier quatre exigences pourtant indissociables d’une authentification digne de confiance : une fusion représentationnelle riche, la robustesse aux modalités dégradées ou absentes, la calibration probabiliste des scores de similarité, et l’explicabilité des décisions. Ce chapitre procède à une revue systématique de la littérature organisée en cinq thèmes, et identifie de manière circonstanciée le gap scientifique que l’architecture UFM-Transformer comble.

1.1 Architectures de Fusion Profonde pour la Biométrie Multimodale

La fusion multimodale en biométrie s’articule traditionnellement autour de trois stratégies — précoce, tardive et hybride — dont les propriétés informationnelles et les vulnérabilités diffèrent radicalement. La compréhension de ces différences est essentielle pour situer l’originalité de l’approche proposée.

1.1.1 Fusion précoce : concaténation et espaces d’embedding joints

La fusion précoce, ou *feature-level fusion*, opère sur les représentations intermédiaires des réseaux profonds en concaténant, additionnant ou multipliant les descripteurs extraits de chaque modalité. Elle domine la littérature récente : sur 45 études examinées entre 2020 et 2026, 25 adoptent cette stratégie [?]. L’attrait théorique est évident — combiner les modalités dans l’espace des caractéristiques préserve la richesse informationnelle et permet au réseau d’apprendre des interactions croisées non linéaires.

Soleymani *et al.* [72] ont posé les bases de la fusion bilinéaire profonde pour la bio-

métrie multimodale en proposant le *Generalized Compact Bilinear* (GCB) fusion, qui capture les interactions multiplicatives entre descripteurs de modalités via une projection *tensor sketch*. Le GCB surpasse systématiquement la concaténation linéaire sur les bases CMU Multi-PIE, BioCop et BIOMDATA, tout en réduisant drastiquement le nombre de paramètres. Les mêmes auteurs étendent ensuite cette approche par une abstraction multi-niveaux, fusionnant les caractéristiques issues de plusieurs couches convolutionnelles de CNNs modali-spécifiques et atteignant 99,34% de précision sur la base BioCop pour la triple modalité visage+iris+empreinte [71].

Les réseaux *cross-stitch* de Misra *et al.* [?], initialement conçus pour l'apprentissage multi-tâche, fournissent un mécanisme adaptatif de partage de représentations en apprenant des combinaisons linéaires des sorties de couches entre réseaux modali-spécifiques. Ruder *et al.* [65] généralisent cette idée via les *sluice networks*, qui apprennent non seulement quelles couches et sous-espaces partager, mais également où les représentations les plus discriminantes se forment — réduisant l'erreur de 12,8% par rapport aux modèles uni-tâche.

La limitation fondamentale de la fusion précoce réside dans sa fragilité face à la dégradation d'une modalité. Lorsqu'une empreinte est bruitée ou qu'un visage est partiellement occlus, les caractéristiques corrompues se propagent directement dans la représentation jointe, compromettant l'intégralité de l'embedding fusionné. Cette vulnérabilité structurelle, soulignée par de multiples travaux [?, ?], motive l'intégration de mécanismes de pondération dynamique ou de gating attentionnel — thèmes développés en 2.5.

1.1.2 Fusion tardive : combinaison au niveau des scores

La fusion tardive, ou *score-level fusion*, constitue la stratégie la plus répandue en déploiement opérationnel. Chaque modalité traverse un pipeline indépendant (extraction, comparaison, production d'un score de similarité), et les scores résultants sont combinés par des règles fixes (somme, produit, min, max) ou par des modèles appris [54].

Nandakumar *et al.* [54] ont établi le cadre théorique dominant en proposant une fusion par ratio de vraisemblance reposant sur l'estimation de densités de mélange gaussiennes pour les distributions de scores *genuine* et *impostor*. Leur approche gère explicitement les scores à échelles arbitraires, corrélés, et intègre les mesures de qualité. Préalablement, Jain *et al.* [34] avaient systématisé les techniques de normalisation (min-max, z-score, tanh) et démontré que la règle de somme appliquée à des scores z-normalisés atteignait 98,6% de GAR à 0,1% de FAR sur des modalités visage, empreinte et géométrie de la main.

Cette élégance modulaire dissimule une limitation informationnelle irréductible. Dass *et al.* [14] avaient déjà formalisé le cadre optimal de fusion par ratio de vraisemblance, démontrant que la règle du produit est optimale sous hypothèse d'indépendance tandis que la règle de la somme est plus robuste aux erreurs d'estimation. Kittler *et al.* avaient

quant à eux établi le cadre théorique des règles de combinaison fixes. Pourtant, ces règles présupposent une fiabilité approximativement égale des modalités, hypothèse systématiquement violée en conditions réelles où une empreinte peut être humide ou un visage partiellement éclairé.

Liang *et al.* [?] caractérisent la fusion décisionnelle comme souffrant de « limitations évidentes » : ses performances sont « contraintes par une seule modalité » et elle est « moins efficace pour capturer les relations profondes entre modalités ». Au niveau du score, la topologie de l'espace de caractéristiques croisées a été irréversiblement perdue — la fusion ne peut plus exploiter les corrélations inter-modales qui existaient dans l'espace des représentations. Les règles de combinaison fixes (somme, produit) présupposent une fiabilité approximativement égale des modalités, hypothèse systématiquement violée en conditions réelles.

Les travaux récents tentent de pallier ces limitations par des approches adaptatives. QMagFace [77] introduit une fonction de comparaison sensible à la qualité exploitant la linéarité entre qualité et score de similarité. Néanmoins, même ces méthodes sophistiquées opèrent sur des scores pré-calculés et ne peuvent pas récupérer l'information inter-modale perdue lors de l'extraction indépendante.

1.1.3 Fusion hybride : architectures multi-étages

La fusion hybride combine les niveaux précoce et tardif en cascade, capitalisant sur les forces complémentaires de chaque approche. Aswin *et al.* [3] démontrent qu'une stratégie hybride (70% score, 30% feature) atteint 99,79% de précision sur NUPT-FPV, surpassant la fusion purement score-level (99,37%) et purement feature-level. De manière analogue, Al-Askar *et al.* [2] rapportent un EER de 0,18% en fusion hybride contre 0,28% en fusion score-level sur la même base.

Cette supériorité s'explique par la complémentarité informationnelle : la fusion précoce capture les caractéristiques biométriques fines, tandis que la fusion tardive reflète la confiance du classifieur. Plusieurs architectures sophistiquées émergent dans ce paradigme. Le *Multimodal Bottleneck Transformer* (MBT) de Nagrani *et al.* [53] force l'information inter-modale à transiter par un petit nombre de *bottleneck latents*, obligeant le modèle à condenser l'information la plus pertinente. AuthFormer [82] combine mécanisme d'attention croisée et *Gated Residual Networks* (GRN) pour fusionner dynamiquement visage, empreinte et voix — atteignant 99,73% de précision avec seulement deux couches d'encodeur.

Le coût computationnel de ces architectures hybrides demeure élevé. La distillation de connaissances parallèle à attention multi-niveaux (MPAD) [45] compresse les réseaux multimodaux complexes via un module de fusion par attention parallèle (PAFM) tout en maintenant les performances. À l'extrême, les réseaux de neurones à spikes (SNN) [68]

atteignent 95,31% de précision sur CASIA avec seulement 1,32 mJ de consommation énergétique — environ le centième des méthodes ANN conventionnelles — par une fusion inspirée de la théorie de l'information *bottleneck*.

QME (*Quality-Guided Mixture of Score-Fusion Experts*) [87], présenté à l'ICCV 2025, propose une stratégie de fusion learnable par *Mixture of Experts* qui s'adapte au bruit capteur, aux occlusions et aux modalités manquantes. AuthFormer et QME représentent l'état de l'art en fusion hybride, mais aucun ne traite nativement les quatre défis simultanément — la quantification d'incertitude, la gestion des modalités manquantes, et l'explicabilité bimodale restent absents.

1.1.4 Synthèse comparative

Le Tableau 1.1 synthétise les propriétés des trois approches.

TABLE 1.1 – Comparaison des stratégies de fusion profonde pour la biométrie multimodale.

Type	Avantages	Limitations	Référence clé
Fusion précoce	Riches interactions croisées ; apprentissage joint de représentations	Propagation de corruption modale ; fragilité à la dégradation	Soleymani <i>et al.</i> [72]
Fusion tardive	Modularité ; gestion simple des modalités manquantes ; facilement déployable	Perte irréversible d'information inter-modale ; poids globaux fixes	Nandakumar <i>et al.</i> [54]
Fusion hybride	Combine les atouts des deux approches ; précision maximale rapportée	Complexité architecturale élevée ; coût computationnel	Aswin <i>et al.</i> [3], Yang <i>et al.</i> [82]

1.2 Mécanismes d'Attention et Transformers pour la Biométrie

1.2.1 Self-attention pour la reconnaissance faciale

L'adoption des *Vision Transformers* (ViT) pour la reconnaissance faciale s'est accélérée après les travaux fondateurs de Zhong & Deng [86]. TransFace [13], présenté à l'ICCV 2023, a identifié les incompatibilités critiques entre l'entraînement ViT et la reconnaissance faciale à grande échelle, proposant une perturbation d'amplitude de patches dominants (DPAP) et une stratégie de minage d'échantillons durs basée sur l'entropie (EHSM) — TransFace-S surpasse ViT-S de +0,56% sur IJB-C à TAR@FAR=10⁻⁴. LV-Face [83] pousse cette logique plus loin avec une optimisation progressive de clusters

(PCO) en trois étapes, atteignant la première place du classement MFR-Ongoing en mars 2025 avec 97,25% TAR@FAR=10⁻⁵. ViT-GCT [11], soumis à l'ICLR 2026, remplace le token CLS classique par un *Global Context Token* qui interagit avec tous les patches via self-attention, induisant un focus renforcé sur les landmarks faciaux clés (+1,0% sur IJB-C à FAR=10⁻⁵).

TopoFR [?] exploite l'homologie persistante pour aligner les structures topologiques entre l'espace d'entrée et l'espace latent, surpassant même TransFace sur certains benchmarks avec un simple ResNet50 — suggérant que la stratégie d'entraînement prime parfois sur l'architecture. FaceCoresetNet [67], présenté à l'AAAI 2024, reformule la reconnaissance d'ensembles faciaux comme un problème de sélection de *coreset* différentiable, utilisant la cross-attention entre un petit ensemble de tokens *core-template* et le template facial complet pour enrichir le descripteur. Ces travaux établissent les transformers comme l'architecture dominante pour la biométrie unimodale.

Pour les empreintes digitales, AFR-Net [24] combine des embeddings CNN (ResNet50) et des blocs d'attention transformer (12 couches, 8 têtes), atteignant 99,78% de rank-1 sur NIST SD14 contre une galerie de 100K — surpassant DeepPrint (99,20%). Ridgeformer [59] introduit une cross-attention entre les tokens de deux échantillons d'empreintes pour l'appariement cross-domain (contactless vers contact). IFViT [62] propose une représentation de longueur fixe interprétable via un réseau siamois ViT avec cross-attention entre paires d'empreintes, établissant des correspondances pixel-à-pixel.

1.2.2 Attention inter-modale : fusion guidée par la qualité

La modulation de l'attention par la qualité de l'échantillon biométrique s'est imposée comme un impératif opérationnel. Soleymani *et al.* [?] démontrent qu'une fusion feature-level guidée par des scores de qualité faiblement supervisés surpasse les fusions rank-level et score-level de plus de 30% en TAR à FAR=10⁻⁴ sur la base BIOMDATA. Ce résultat est crucial : il établit que la modulation de la qualité doit impérativement opérer au niveau des représentations, et non des scores, pour être informationnellement efficace.

Gnanapraveen *et al.* [?], présenté à Odyssey 2024, confirment empiriquement la supériorité de l'attention croisée : sur la reconnaissance audio-visuelle de personnes, l'attention croisée atteint un EER de 2,387 contre 2,412 (self-attention), 2,489 (concaténation de features) et 2,521 (fusion score-level). Cette hiérarchie — cross-attention > self-attention > concaténation > score-level — fournit un argument quantitatif solide pour le positionnement d'UFM-Transformer. Elle suggère également une dualité fonctionnelle essentielle : les poids d'attention servent simultanément à moduler la fusion et à fournir une explication inhérente des décisions, chaque poids révélant quelle région d'une modalité « regarde » quelle région de l'autre. Cette propriété *dual-use*, exploitée explicitement dans UFM-Transformer, n'a pas été reconnue comme telle dans les travaux existants : Tiong *et al.* [80]

utilisent l'attention pour la fusion mais ne visualisent pas les patterns attentionnels ; Selvarani & Rani [66] analysent les poids d'attention mais via SHAP/LIME *post-hoc*.

1.2.3 Les transformers croisés : de la vision multimodale à la biométrie

L'attention croisée entre modalités biométriques distinctes reste paradoxalement sous-explorée. Tiong *et al.* [80] proposent MFA-ViT (*Multimodal Fusion Attention*), qui établit l'état de l'art pour la reconnaissance face+péριο-oculaire par une attention de fusion multimodale combinée à un *prompt tuning* multimodal — évitant le *fine-tuning* spécifique à chaque modalité. Les *Tiny Transformers* [79] intègrent un mécanisme de *Quality-Gated Fusion* utilisant un MLP léger pour pondérer dynamiquement les scores de similarité selon la qualité d'entrée (mesure de netteté Laplacienne).

Plusieurs architectures récentes illustrent la richesse du paradigme transformer pour la fusion, sans toutefois combler le gap visé. AuthFormer [82] emploie une attention croisée entre visage, empreinte et voix suivie de réseaux résiduels à gating (GRN) pour un poids total réduit — seulement deux couches d'encodeur suffisent à atteindre 99,73% de précision sur la base LUTBIO. Les *Tiny Transformers* [79] proposent une architecture hybride ViT+Swin avec fusion par gating de qualité, atteignant une latence inférieure à 50ms avec moins de 3 millions de paramètres. QME [87] adopte une *Mixture of Experts* guidée par la qualité pour la reconnaissance biométrique *whole-body* (visage+démarche+corps), adaptant dynamiquement la stratégie de fusion au bruit capteur et aux modalités absentes.

Pourtant, une observation d'importance critique émerge de cette revue : aucun travail publié n'implémente une attention croisée inter-modale *directe* entre des patches faciaux et des patches d'empreintes digitales au sein d'un espace transformer partagé. Les approches multimodales existantes utilisent systématiquement des encodeurs séparés suivis d'une fusion tardive — au niveau des scores ou par concaténation d'embeddings. MFA-ViT [80] applique l'attention croisée au couple face+péριο-oculaire ; les transformers audio-visuels [?] traitent le couple voix+visage ; AuthFormer [82] fusionne visage, empreinte et voix mais par attention croisée séquentielle avec encodeurs séparés, non par co-embedding token-level des patches visage et empreinte dans un espace transformer unifié. Cette absence constitue le premier pilier du gap que UFM-Transformer comble.

1.2.4 Gap : absence d'attention croisée visage-empreinte

L'attention croisée a été appliquée au visage+péριο-oculaire [80], au visage+voix [?], et à l'empreinte+veine de doigt [81]. Mais la paire visage-empreinte digitale — pourtant la plus déployée opérationnellement — n'a jamais fait l'objet d'une étude dédiée avec attention croisée token-level. UFM-Transformer propose précisément cette architecture inédite.

1.3 Robustesse aux Données Dégradées et Modalités Absentes

1.3.1 Reconnaissance faciale robuste : occlusion, flou, bruit

La reconnaissance faciale sous dégradation a connu des avancées substantielles portées par des fonctions de perte adaptatives à la qualité. AdaFace [38] introduit une marge adaptative fonction de la qualité estimée par la norme du feature vector, améliorant l'état de l'art sur IJB-B, IJB-C, IJB-S et TinyFace. MagFace [52] génère des embeddings sensibles à la qualité par une marge angulaire consciente de la magnitude, naturellement exploitée par QMagFace [77] pour des scores de comparaison sensibles à la qualité (98,74% sur CFP-FP).

L'estimation de qualité faciale (FIQA) a atteint une maturité significative. CR-FIQA [8] apprend la classifiabilité relative d'échantillons en sondant les observations internes du réseau durant l'entraînement, classant 1er/2ème à l'évaluation NIST FATE Quality. SER-FIQ [78] propose une approche non supervisée exploitant la robustesse stochastique de sous-réseaux aléatoires. GraFIQs [40] introduit une approche complètement *training-free* exploitant les magnitudes de gradient des statistiques de *Batch Normalization*.

Pour l'occlusion, WebFace-OCC [?] propose une base de 804 704 images synthétiquement occluses de 10 575 sujets ; l'entraînement d'ArcFace sur cette base améliore significativement la robustesse. SlackedFace [44] introduit une marge « relâchée » pour la reconnaissance basse-résolution, dévalorisant les échantillons durs non reconnaissables — atteignant 80% de rank-1 sur SCFace D1 étendu. La question de la *cross-quality matching* a été formalisée par la base XQLFW [39], qui révèle une chute de performance de 25,28% pour ArcFace comparé à LFW standard, mettant en évidence que les performances sur bases contrôlées ne prédisent pas la robustesse réelle en conditions dégradées.

1.3.2 Reconnaissance d'empreintes dégradées : partielles, latentes, sans contact

La reconnaissance d'empreintes partielles a migré des approches par minuties aux représentations profondes de longueur fixe. PFVNet [28] apprend une vérification d'empreintes partielles à partir de grandes bases d'appariement, produisant des embeddings invariants à la pose. JIPNet [25] optimise conjointement la vérification d'identité et l'alignement de pose. Pour les empreintes latentes, LFR-Net [23] fusionne des descripteurs de minuties locaux avec des embeddings globaux AFR-Net via une stratégie de recherche multi-étages — 84,11% de rank-1 sur NIST SD27 contre une galerie de 100K.

Le passage aux capteurs sans contact post-COVID a intensifié la recherche. C2CL [22] atteint un TAR de 96,67–98,30% à FAR=0,01% pour l'appariement cross-capteur

en combinant pré-traitement (segmentation, enhancement, déroulage) avec appariement hybride minuties+texture. La qualité des empreintes sans contact pose un défi spécifique : MCLFIQ [61] montre que NFIQ 2.0 se dégrade sur les données contactless, nécessitant un réentraînement spécifique. L'approche la plus prometteuse pour la généralisation cross-capteur reste l'apprentissage auto-supervisé : Gazi *et al.* [21] démontrent qu'un DINOv2-Base (86M paramètres) fine-tuné sur 64 801 images de 12 bases hétérogènes atteint 5,56% d'EER en test multi-capteur, contre 26,90% pour VeriFinger et 41,95% pour SourceAFIS — soit une amélioration relative de $4,8\times$ sur les systèmes commerciaux.

1.3.3 Estimation de qualité : NFIQ 2.0 et réseaux profonds

NFIQ 2.0 [73], standard ISO/IEC 29794-1, fournit une mesure de qualité dans $[0,100]$ via une forêt aléatoire entraînée sur 74 caractéristiques de qualité. Pourtant, Priesnitz *et al.* [60] démontrent à l'BIOSIG 2025 que des CNN fine-tunés (VGG16) surpassent NFIQ 2.3 de 12,29% en performance prédictive mesurée par courbes EDC. MCLFIQ [61] adapte NFIQ 2.0 aux empreintes sans contact mobiles, surpassant NFIQ 2.2 sur toutes les bases testées. Pour le visage, les normes ISO/IEC 29794-5 définissent des mesures de qualité heuristiques tandis que les méthodes d'UQ profonde (CR-FIQA, SER-FIQ) apprennent l'incertitude directement des données. Le lien entre ces deux approches — qualité heuristique standardisée et incertitude apprise — demeure inexploré et sera investigué dans ce mémoire.

1.3.4 Gestion des modalités manquantes : un retard critique

La gestion des modalités manquantes constitue le retard le plus flagrant de la biométrie par rapport aux domaines voisins. En imagerie médicale, des solutions sophistiquées existent : SMIL [48] gère jusqu'à 90% de données manquantes par méta-régularisation bayésienne ; mmFormer [84] traite toute sous-ensemble de modalités IRM ; le *prompt tuning* avec modalités manquantes [42] nécessite moins de 1% de paramètres apprenables ; les *Cross-Modal Proxy Tokens* (CMPT) [63] approximent le token de classe d'une modalité absente à partir des modalités disponibles.

En biométrie multimodale, la situation est radicalement différente. Sur 17 méthodes de gestion de modalités manquantes recensées, seules 3 sont spécifiquement biométriques — et toutes utilisent des approches non profondes (*fallback* score-level ou fusion décisionnelle) [17,41,68]. Shen *et al.* [68] introduisent le *Multimodal Adaptive Dropout* (MAD) pour l'équilibrage modal lors de l'entraînement, mais cible l'*imbalance* plutôt que l'absence à l'inférence. El-Bousty *et al.* [17] implémentent des stratégies de repli explicites pour l'authentification mono- et bi-modale. Korse *et al.* [41] proposent une fusion décisionnelle avec détection de contradiction et gating de fiabilité pour le contrôle d'accès. Aucun de ces travaux n'adopte les méthodes d'avant-garde du machine learning général (proxy to-

kens, prompt tuning, LoRA adaptation) pour compenser les modalités manquantes au niveau représentationnel. Ma *et al.* [47] ont établi de manière frappante que les transformers multimodaux ne sont *pas* naturellement robustes aux modalités manquantes — ils peuvent même performer *moins bien* que des modèles unimodaux. Neverova *et al.* [56] avaient introduit le *ModDrop* (abandon aléatoire de canaux modaux durant l'entraînement), technique fondamentale mais sous-utilisée en biométrie. Ce retard de plus de cinq ans par rapport à l'imagerie médicale constitue le deuxième pilier du gap identifié.

1.4 Quantification d'Incertitude et Calibration des Scores

1.4.1 Incertitude en apprentissage profond : épistémique vs aléatoire

La distinction entre incertitude épistémique (liée au modèle, réductible avec plus de données) et incertitude aléatoire (liée aux données, irréductible), formalisée par Kendall & Gal [37], structure les approches contemporaines. En biométrie, cette dichotomie revêt une importance opérationnelle : l'incertitude épistémique signale un manque de connaissance du système (nouvelle identité, biais de distribution), tandis que l'incertitude aléatoire reflète la qualité dégradée de l'échantillon (flou, occlusion, bruit capteur). Cette séparation motive la modélisation probabiliste des embeddings dans UFM-Transformer, où la variance du modèle capture l'incertitude épistémique et la variance des features capture l'incertitude aléatoire.

Trusted Multi-View Classification (TMC) [26] illustre cette convergence en appliquant l'apprentissage profond évidentiel avec fusion dynamique de Dempster-Shafer pour la classification multi-vue. Bien que non spécifique à la biométrie, ce cadre fournit une méthode principielle pour fusionner des preuves incertaines de vues multiples avec quantification explicite de l'incertitude — une philosophie directement transposable à la fusion visage-empreinte.

1.4.2 Monte-Carlo Dropout et Deep Ensembles

Joshi *et al.* [35] ont appliqué le MC-Dropout à l'amélioration d'empreintes via MUGAN et DU-GAN, démontrant que l'incertitude modèle est élevée aux pixels incorrectement prédits tandis que l'incertitude données est élevée sur les régions bruitées. Cependant, le MC-Dropout multiplie le temps d'inférence par dix (49,32ms contre 5,13ms pour 10 échantillons). Les *Deep Ensembles*, pourtant *gold standard* en UQ selon Fort *et al.* [18], demeurent sous-utilisés en biométrie — la plupart des travaux se limitent à des approches single-model. HUE-Net [33] propose une architecture combinant MC-Dropout avec rétro-propagation bayésienne pour quantifier les deux types d'incertitude en reconnaissance

faciale sous conditions adverses, mais reste uni-modal.

1.4.3 Embeddings probabilistes : PFE, DUL et au-delà

Les *Probabilistic Face Embeddings* (PFE) de Shi & Jain [69] représentent chaque image faciale comme une distribution gaussienne $\mathcal{N}(\mathbf{z}; \boldsymbol{\mu}, \boldsymbol{\sigma}^2)$ dans l'espace latent, où $\boldsymbol{\mu}$ encode l'identité et $\boldsymbol{\sigma}^2$ quantifie l'incertitude. Le *Mutual Likelihood Score* (MLS) remplace la similarité cosinus pour l'appariement, améliorant les performances et fournissant de « bons indicateurs de la précision d'appariement potentielle ».

Chang *et al.* [?] étendent le PFE par l'apprentissage conjoint de la représentation et de l'incertitude (*Data Uncertainty Learning*), atteignant 90,23% de TPR@FPR=10⁻⁵ sur IJB-C contre 89,64% (PFE) et 83,06% (baseline). La variance apprise corrèle avec la dégradation de qualité de l'image et sert d'« indicateur de risque ». Chen *et al.* [10] proposent une modélisation par double gaussienne, séparant les échantillons faciles des échantillons difficiles (poses extrêmes, bruit important) par deux distributions distinctes, corrélant l'incertitude avec plusieurs attributs simultanément.

HolUE [?] combine l'incertitude *gallery-aware* (GalUE) avec des estimations de qualité via un modèle bayésien, surpassant PFE, SCF et SF pour la reconnaissance ouverte contrôlée en risque sur IJB-C. LAM (*Laplace Approximation Metric learning*) [9] emploie l'approximation de Laplace sur les poids du réseau plutôt que l'amortissement neuronal, produisant des incertitudes bien calibrées avec un ECE inférieur aux méthodes MC-Dropout et Deep Ensembles.

1.4.4 Calibration : ECE, MCE, temperature scaling

La calibration des scores de similarité biométriques reçoit une attention renouvelée. L'*Expected Calibration Error* (ECE) et le *Maximum Calibration Error* (MCE), empruntés à la littérature de classification, mesurent l'écart entre la confiance prédite et la précision effective. Conti *et al.* [12], présenté à l'ICLR 2024, démontrent que le bootstrap naïf échoue pour le scoring de similarité car les FAR/FRR sont des U-statistiques ; leur bootstrap recentré fournit des bandes de confiance valides autour des courbes ROC et des métriques d'équité. Le *temperature scaling* et le *Platt scaling*, standards en classification, n'ont pas été systématiquement validés pour les distributions de scores de similarité biométriques — où les sorties sont des similarités cosinus ou des distances euclidiennes plutôt que des probabilités softmax. La prédiction conforme (*Conformal Prediction*) [7], offrant des garanties de couverture à échantillon fini, demeure inexplorée pour la fusion biométrique multimodale. Ces lacunes motiveront la procédure de calibration développée au Chapitre 2.

1.4.5 Gap : aucun système biométrique multimodal avec quantification d'incertitude

Malgré la richesse des travaux sur l'incertitude unimodale et la fusion multimodale, leur intersection demeure quasiment vide. Seuls deux travaux émergent : la fusion Dempster-Shafer de Nguyen *et al.* [57] modélise explicitement trois masses (*genuine*, *impostor*, *incertain*) au niveau des scores ; et la fusion context-aware de Zibert *et al.* [88] détecte les contradictions entre modalités biométriques au niveau décisionnel. Aucun système ne propage l'incertitude de chaque modalité à travers le processus de fusion pour produire des scores de confiance multimodaux calibrés avec option de rejet. Ce constat constitue le troisième pilier du gap.

1.5 Explicabilité des Systèmes Biométriques Multimodaux

1.5.1 Grad-CAM et dérivés pour la reconnaissance faciale

Les méthodes de visualisation par gradient, dominées par Grad-CAM et Grad-CAM++ [?], ont été largement adoptées pour expliquer les décisions de reconnaissance faciale. Pourtant, Lu *et al.* [46], présenté au WACV 2024, établissent que ces méthodes produisent des cartes de saillance moins stables et moins significatives que les approches par perturbation. Leur méthode CorrRISE (*Correlation-based Randomized Input Sampling for Explanation*) surpasse systématiquement Grad-CAM, Grad-CAM++, LIME, RISE, MinPlus et xFace sur les benchmarks de vérification faciale — avec un taux de suppression (Deletion) de 23,29% contre 50,65% pour Grad-CAM sur LFW.

La survey de Neto *et al.* [55] établit une taxonomie systématique des techniques XAI pour la biométrie, structurant le domaine selon une « échelle XAI » à trois niveaux : visualisation par gradient, méthodes post-hoc apprenables, et conception ante-hoc interprétable. Le champ connaît une tension méthodologique structurante : les méthodes par gradient (Grad-CAM, xSSAB) privilégient l'efficacité computationnelle tandis que les méthodes par perturbation (CorrRISE, RISE) offrent des explications de meilleure qualité mais à un coût bien supérieur. Sur le benchmark Patch-LFW [32], CorrRISE atteint un taux d'insertion (Insertion) de 85,70% contre 65,00% pour Grad-CAM, établissant une hiérarchie de qualité claire. Cependant, cette qualité s'acquiert au prix d'une latence incompatible avec le temps réel — ce qui motive l'approche d'explicabilité *ante-hoc* d'UFM-Transformer, où les poids d'attention sont des sous-produits gratuits de la fusion.

Huber *et al.* [32] proposent xSSAB (*similarity score argument backpropagation*), une approche *white-box training-free* qui rétro-propage le score de similarité cosinus à travers un réseau siamois pour indiquer les zones similaires et dissimilaires. Lin *et al.* [43] dé-

veloppent xCos, un module apprenable fournissant des explications spatiales pondérées par l'attention. Rocha *et al.* [64] introduisent ProtoSiamese et MaskSiamese, des réseaux siamois intrinsèquement interprétables par comparaison explicite patch-à-patch.

1.5.2 Cartes d'attention pour l'importance des minuties d'empreinte

Tan & Kumar [75] proposent un réseau d'attention aux minuties avec *reciprocal distance loss*, générant des cartes de vraisemblance des minuties servant de cartes d'attention pour guider le réseau vers les zones distordues. Découverte plus récente et d'importance capitale : Gazi *et al.* [21] démontrent qu'un ViT auto-supervisé DINOv2 pour l'empreinte digitale apprend spontanément des cartes d'attention qui s'alignent avec les régions riches en minuties ($\text{IoU} = 0,41 \pm 0,07$), bien qu'aucune supervision minutie n'ait été fournie. Les tokens d'attention se concentrent systématiquement sur les transitions de crêtes, les régions à forte courbure et les motifs ressemblant à des bifurcations — éléments structuraux discriminants par excellence. Ce phénomène — l'explicabilité « gratuite » des transformers auto-supervisés — constitue un argument fort pour l'adoption de backbones ViT dans UFM-Transformer, car il promet que les poids d'attention croisée entre visage et empreinte seront intrinsèquement interprétables, révélant quelles régions faciales correspondent à quelles zones d'empreinte pour l'appariement identitaire.

1.5.3 Explicabilité multimodale : SHAP, LIME, attention cross-modale

Selvarani & Rani [66] intègrent pour la première fois SHAP et LIME dans un pipeline d'authentification multimodale (visage, empreinte, paume), quantifiant les contributions modales : visage 48%, empreinte 31%, paume 21%. Leur réseau de fusion cross-modale par attention alloue dynamiquement l'importance à chaque modalité. Cependant, SHAP et LIME fournissent une explicabilité *post-hoc* : ils expliquent une décision déjà prise sans que le mécanisme explicatif ne soit intégré à l'architecture. Cette séparation entre raisonnement et explication limite la confiance opérationnelle, d'autant que les méthodes *post-hoc* peuvent produire des explications inconsistents avec le comportement réel du modèle [55].

La taxonomie de Neto *et al.* [55] établit une « échelle XAI » à trois niveaux : (1) visualisation par gradient, (2) méthodes post-hoc apprenables, (3) conception ante-hoc interprétable. Les réseaux d'attention graphe (GAT) de Harini *et al.* [27] représentent un pas vers l'ante-hoc en traitant les modalités biométriques comme des nœuds d'un graphe pleinement connecté, les poids d'attention inter-modaux fournissant une explicabilité inhérente. ProtoSiamese et MaskSiamese [64] vont plus loin en proposant des réseaux

siamois intrinsèquement interprétables par comparaison explicite patch-à-patch, MaskSiamese surpassant même le réseau siamois boîte-noire tout en fournissant des explications significatives.

1.5.4 Gap : absence d'explication visuelle bimodale unifiée

Aucun travail publié ne fournit d'explications visuelles unifiées mettant simultanément en évidence les régions faciales *et* les points minuties d'empreinte ayant contribué à une décision bimodale. Les travaux existants quantifient les contributions au niveau modalité (SHAP) ou génèrent des cartes de saillance unimodales (CorrRISE pour le visage, attention aux minuties pour l'empreinte), mais jamais les deux simultanément dans une visualisation fusionnée. Ce quatrième gap est représenté schématiquement à la Figure 1.1.




FIGURE 1.1 – Illustration schématique du gap d'explicabilité bimodale : (a) explication unimodale visage par CorrRISE, (b) explication unimodale empreinte par attention aux minuties, (c) l'explication bimodale unifiée que UFM-Transformer fournit via les poids d'attention croisée. Aucun travail existant ne produit (c).

1.6 Identification du Gap et Positionnement

1.6.1 Synthèse des gaps par dimension

Le Tableau 1.2 synthétise les lacunes identifiées pour chaque dimension, avec les travaux les plus proches et leurs limites.

TABLE 1.2 – Synthèse des gaps scientifiques par dimension de l'état de l'art.

Dimension	Gap identifié	Travaux les plus proches	Limite de ces travaux
Fusion	Aucune attention croisée token-level entre patches visage et patches empreinte	Tiong <i>et al.</i> [80] (face+péριο-oculaire) ; Gnanapraveen <i>et al.</i> [?] (audio-visuel)	Modalités différentes ; pas de paire visage-empreinte
Robustesse	Aucune gestion native de modalités manquantes pour visage+empreinte	SMIL [48], CMPT [63], Lee <i>et al.</i> [42]	Domaine imagerie médicale ; jamais appliqué à la biométrie
Incertitude	Aucun système ne propage l'incertitude à travers la fusion multimodale	PFE/DUL [?, 69] (unimodal) ; Dempster-Shafer [57]	Uniquement au niveau des scores ; pas de propagation feature-level
Explicabilité	Aucune explication visuelle bimodale unifiée	CorrRISE [46] (visage) ; attention minuties [75] (empreinte)	Explications unimodales séparées

1.6.2 UFM-Transformer face aux travaux existants

Le Tableau 1.3 positionne UFM-Transformer contre six représentants de l'état de l'art les plus proches, selon huit critères de comparaison.

TABLE 1.3 – Comparatif d'UFM-Transformer avec les travaux les plus proches de l'état de l'art selon huit dimensions. ✓ = satisfait pleinement, (o) = satisfait partiellement, × = non satisfait.

Critère	[82]	[87]	[80]	[?]	[69]	[46]	UFM-T
Fusion feature-level	✓	×	✓	✓	×	×	✓
Attention croisée modale	✓	×	✓	×	×	×	✓
Modulation par qualité	(o)	✓	(o)	✓	×	×	✓
Modalités manquantes	(o)	(o)	×	×	×	×	✓
Quantif. incertitude	×	×	×	×	✓	×	✓
Explicabilité visuelle	×	×	×	×	×	✓	✓
Explicabilité bimodale	×	×	×	×	×	×	✓
Calibration probabiliste	×	×	×	×	(o)	×	✓

1.6.3 Le gap central

L'analyse systématique de plus de 150 articles couvrant dix dimensions de recherche révèle un phénomène structurel : la littérature biométrique s'est fragmentée en « îlots architecturaux » non communicants [?]. Les chercheurs en fusion précoce optimisent la concaténation de features ; ceux en fusion tardive affinent les règles de combinaison de scores ; les communautés d'incertitude et d'explicabilité évoluent séparément. À travers ces 150 travaux, aucun ne satisfait plus de deux des quatre exigences simultanément.

AuthFormer [82] atteint l'attention croisée avec adaptation modale mais ignore l'incertitude, les modalités manquantes et l'explicabilité bimodale. QME [87] gère la qualité et les modalités manquantes mais opère au niveau des scores et ne quantifie pas l'incertitude. PFE/DUL [?, 69] fournissent des embeddings probabilistes calibrés mais pour la reconnaissance faciale unimodale uniquement. CorrRISE [46] offre une explicabilité visuelle sophistiquée mais pour le visage seul.

Le gap central que ce mémoire comble s'énonce ainsi : *aucun système biométrique multimodal existant ne traite simultanément les quatre défis* — (i) attention croisée visage-empreinte avec modulation par qualité au niveau token, (ii) gestion native des modalités manquantes sans modification architecturale à l'inférence, (iii) propagation de l'incertitude à travers la fusion pour produire des scores calibrés avec option de rejet, et (iv) explication visuelle bimodale unifiée. UFM-Transformer propose une architecture originale qui intègre ces quatre capacités dans un seul framework différentiable, rendant chaque composante — les poids d'attention, les estimations d'incertitude, les cartes d'explication — des sous-produits naturels d'un même mécanisme d'attention croisée probabiliste.

Cette unification architecturale ne se contente pas de coexister quatre techniques séparées : elle les fait interagir de manière synergique. Les poids d'attention croisée modulent la fusion tout en fournissant l'explicabilité ; les variances de features, propagées par la loi de la variance totale, quantifient l'incertitude tout en informant la modulation par qualité ; le *modality dropout* durant l'entraînement prépare l'architecture à l'absence de modalités tout en générant des données de calibration naturelles. Cette cohérence interne distingue fondamentalement UFM-Transformer d'une simple juxtaposition de modules. Le chapitre suivant développe formellement cette architecture, ses équations de propagation, et sa procédure d'entraînement.

Chapitre 2

Le Modèle UFM-Transformer

Ce chapitre présente en détail l’architecture UFM-Transformer (*Uncertainty-aware Fusion Multimodal Transformer*), conçue pour la vérification biométrique multimodale associant visage et empreinte digitale. L’exposé vise une reproductibilité intégrale : chaque choix de conception est justifié, chaque hyperparamètre est explicité, et les flux de dimensions tensorielles sont indiqués à chaque étape du traitement. L’architecture unifie quatre fonctions rarement conjuguées dans la littérature biométrique : la fusion par attention croisée entre modalités, la gestion native des modalités manquantes, la quantification de l’incertitude, et l’explicabilité bimodale inhérente à l’attention.

2.1 Formulation du Problème

2.1.1 Notations et définitions formelles

On définit l’espace des entrées bimodales. Une image faciale est notée $\mathbf{x}_f \in \mathcal{X}_f = \mathbb{R}^{3 \times H_f \times W_f}$, où $H_f = W_f = 224$ désignent la résolution spatiale et le canal de profondeur 3 correspond aux composantes RGB. Une image d’empreinte digitale est notée $\mathbf{x}_p \in \mathcal{X}_p = \mathbb{R}^{1 \times H_p \times W_p}$, avec $H_p = W_p = 224$, le canal unique correspondant à l’intensité en niveaux de gris. Un échantillon d’entraînement est un triplet $(\mathbf{x}_f, \mathbf{x}_p, y)$, où $y \in \{0, 1\}$ est l’étiquette binaire indiquant si la paire appartient à la même identité ($y = 1$) ou à des identités différentes ($y = 0$).

L’ensemble des identités est noté $\mathcal{I} = \{1, \dots, N_{\text{id}}\}$. Chaque identité i est représentée dans la galerie par un gabarit (*template*) bimodal $\mathbf{G}_i = (\mathbf{g}_f^{(i)}, \mathbf{g}_p^{(i)})$, où $\mathbf{g}_f^{(i)}$ et $\mathbf{g}_p^{(i)}$ désignent respectivement les caractéristiques faciales et papillaires de référence. À l’inference, une requête $\mathbf{Q} = (\mathbf{q}_f, \mathbf{q}_p)$ est comparée à l’ensemble des gabarits de la galerie.

On introduit le vecteur de présence modalitaire $\mathbf{m} = (m_f, m_p) \in \{0, 1\}^2$, où $m_f = 1$ (resp. $m_p = 1$) indique que la modalité visage (resp. empreinte) est disponible. Le cas $\mathbf{m} = (1, 1)$ correspond au scénario bimodal complet ; les cas $(1, 0)$ et $(0, 1)$ décrivent les défaillances unimodales de capteur.

2.1.2 Objectif de vérification ouverte avec qualité variable et modalités partielles

Le problème de vérification biométrique ouverte (*open-set verification*) consiste à apprendre une fonction de similarité paramétrée $s_\theta : \mathcal{X}_f \times \mathcal{X}_p \times \mathcal{X}_f \times \mathcal{X}_p \rightarrow \mathbb{R}$ telle que :

$$s_\theta(\mathbf{q}_f, \mathbf{q}_p; \mathbf{g}_f^{(i)}, \mathbf{g}_p^{(i)}) > \tau \iff \mathbf{Q} \text{ et } \mathbf{G}_i \text{ partagent la même identité,} \quad (2.1)$$

où $\tau \in \mathbb{R}$ est un seuil de décision. Dans le cadre de ce mémoire, trois contraintes supplémentaires étendent ce problème standard.

Contrainte de qualité variable. Les scores de qualité $q_f, q_p \in [0, 1]$ sont associés à chaque image. La fonction de similarité doit être modulée par ces scores de manière à atténuer l'influence des modalités dégradées. Formellement, on impose que la similarité s dépende de q_f et q_p au premier ordre : $\frac{\partial s}{\partial q_f} > 0$ et $\frac{\partial s}{\partial q_p} > 0$ en moyenne sur les paires génuines.

Contrainte de modalités partielles. Lorsqu'une modalité est absente ($m_k = 0$), le système doit produire une similarité dégradée gracieusement, sans nécessiter de branche architecturale spécifique. On formalise cette exigence par la condition de continuité :

$$\lim_{q_k \rightarrow 0} s_\theta(\cdot; q_f, q_p) = s_\theta^{\setminus k}(\cdot), \quad (2.2)$$

où $s_\theta^{\setminus k}$ désigne la similarité unimodale obtenue lorsque seule la modalité complémentaire est disponible.

Contrainte d'incertitude calibrée. Le système doit produire, en plus du score de similarité s , une estimation d'incertitude $\sigma^2 \in \mathbb{R}_+$ telle que la probabilité de bonne classification conditionnellement à σ^2 satisfasse :

$$\mathbb{P}(\hat{y} = y \mid \sigma^2 = v) \approx 1 - v/\sigma_{\max}^2, \quad (2.3)$$

c'est-à-dire que l'incertitude doit être une prédiction calibrée de la probabilité d'erreur.

2.2 Vue d'Ensemble de l'Architecture

2.2.1 Pipeline global : encodeurs $\rightarrow$ projecteurs $\rightarrow$ transformer cross-modal $\rightarrow$ têtes de décision

L'architecture UFM-Transformer s'organise en quatre modules fonctionnels connectés en série, chacun résolvant un sous-problème distinct.

Le **module d'encodage modalitaire** (§2.3) extrait des représentations spécialisées pour chaque modalité. L'encodeur visage $\mathcal{E}_f$ est un EfficientNet-B2 [76] pré-entraîné sur

ImageNet, produisant une carte de caractéristiques $\mathbf{z}_f \in \mathbb{R}^{1408 \times 7 \times 7}$. L'encodeur empreinte $\mathcal{E}_p$ est un CNN résiduel personnalisé, produisant $\mathbf{z}_p \in \mathbb{R}^{512 \times 7 \times 7}$. Deux estimateurs de qualité légers $\mathcal{Q}_f$ et $\mathcal{Q}_p$, implémentés comme des CNN à trois couches, produisent les scores $q_f, q_p \in [0, 1]$.

Le **module de projection** (§2.4) aplait et projette les caractéristiques sur une hypersphère commune de dimension $d = 256$. Les projecteurs $\mathcal{P}_f : \mathbb{R}^{1408 \times 7 \times 7} \rightarrow \mathbb{S}^{255}$ et $\mathcal{P}_p : \mathbb{R}^{512 \times 7 \times 7} \rightarrow \mathbb{S}^{255}$ produisent respectivement $\mathbf{h}_f$ et $\mathbf{h}_p$, avec $\|\mathbf{h}_f\|_2 = \|\mathbf{h}_p\|_2 = 1$. Un token apprenable $\mathbf{t}_{\text{miss}} \in \mathbb{R}^{256}$ remplace la représentation d'une modalité absente.

Le **module de fusion par attention croisée** (§2.5) constitue le cœur architectural. Un empilement de $L = 4$ couches de transformer à attention croisée bidirectionnelle, chacune avec $H = 8$ têtes et une dimension latente $d = 256$, produit un token fusionné $\mathbf{c} \in \mathbb{R}^{256}$. Les scores de qualité q_f et q_p modulent les logits d'attention avant le *softmax*, garantissant que les modalités dégradées contribuent moins au résultat fusionné.

Le **module de décision** (§2.6) comprend deux têtes. La tête de similarité $\mathcal{S}$ calcule un score cosinus avec marge additive ArcFace [15] de paramètres $m = 0,5$ et $s = 30$. La tête d'incertitude $\mathcal{U}$ effectue $K = 5$ passes avant avec dropout actif [20] pour produire une décomposition de l'incertitude en composantes aléatoire et épistémique, ainsi qu'un intervalle de confiance associé à la décision.

La figure 2.1 synthétise l'ensemble du pipeline. Le flux de données y est représenté avec les dimensions tensorielles à chaque étape.

2.2.2 Figure : diagramme d'architecture complet avec flux de données

2.3 Encodeurs Spécifiques par Modalité

2.3.1 Encodeur visage : EfficientNet-B2, pré-entraînement ImageNet, extraction de cartes de caractéristiques

L'encodeur visage adopte EfficientNet-B2 [76], dont le profil de complexité (9,2 M de paramètres, 0,69 GFLOPs à la résolution 224×224) offre un compromis favorable entre capacité de représentation et coût de calcul. Ce réseau, pré-entraîné sur ImageNet-1K (1000 classes, 1,28 M d'images), est gelé lors des 50 premières époques de pré-entraînement unimodal, puis dégelé avec un taux d'apprentissage réduit de $\eta = 10^{-5}$ lors du *fine-tuning* joint.

Une entrée faciale $\mathbf{x}_f \in \mathbb{R}^{3 \times 224 \times 224}$, préalablement alignée par détection des points caractéristiques et normalisée par les moyennes et écarts-types d'ImageNet ($\mu = [0,485, 0,456, 0,406]$, $\sigma = [0,229, 0,224, 0,225]$), traverse les sept blocs de convolution composés du réseau. La sortie du cinquième bloc, avant le *global average pooling*, constitue la carte de caractéris-



FIGURE 2.1 – Architecture complète de l’UFM-Transformer. Les dimensions tensorielles sont indiquées à chaque étape. Les flèches en trait plein représentent les flux de données ; les flèches en pointillés représentent les scores de qualité modulant l’attention. Le symbole $\otimes$ dénote la modulation multiplicative des logits d’attention par le produit $q_f \cdot q_p$.

tiques retenue :

$$\mathbf{z}_f = \mathcal{E}_f(\mathbf{x}_f) \in \mathbb{R}^{1408 \times 7 \times 7}, \quad (2.4)$$

où 1408 est la profondeur du canal de sortie de l'avant-dernier bloc et 7×7 la résolution spatiale résiduelle. Ce choix de capturer les caractéristiques avant agrégation spatiale préserve l'information de localisation nécessaire à l'attention croisée ultérieure : chaque position spatiale (i, j) de $\mathbf{z}_f$ peut être mise en correspondance avec une région de l'image faciale originale via le facteur de sous-échantillonnage total $32\times$.

2.3.2 Encodeur empreinte : CNN résiduel personnalisé pour les motifs de crêtes

Les empreintes digitales possèdent des propriétés structurelles distinctes : invariance par translation, orientation locale des crêtes, et richesse en minuties. Un encodeur dédié, plutôt qu'un réseau de vision générique, permet d'exploiter ces spécificités. L'encodeur $\mathcal{E}_p$ est un CNN résiduel à 18 couches, inspiré de l'architecture de Grosz & Jain [24] pour la reconnaissance d'empreintes.

La structure de $\mathcal{E}_p$ se compose de quatre blocs résiduels. Chaque bloc contient deux couches de convolution 3×3 avec normalisation par batch et activation ReLU, suivies d'une connexion résiduelle. Le nombre de filtres progresse de 64 (bloc 1) à 128 (bloc 2), 256 (bloc 3) et 512 (bloc 4). Un max-pooling 2×2 avec stride 2 est appliqué entre chaque bloc. La sortie de l'avant-dernier bloc, avant agrégation spatiale, est :

$$\mathbf{z}_p = \mathcal{E}_p(\mathbf{x}_p) \in \mathbb{R}^{512 \times 7 \times 7}, \quad (2.5)$$

où $\mathbf{x}_p \in \mathbb{R}^{1 \times 224 \times 224}$ est l'image d'empreinte, préalablement normalisée à l'intervalle $[0, 1]$ et augmentée par rotation aléatoire dans $[-15^\circ, +15^\circ]$ ainsi que par ajustement de contraste.

Le nombre total de paramètres de $\mathcal{E}_p$ est de 11,2 M. Cet encodeur est entraîné *from scratch* (sans pré-entraînement) avec la perte ArcFace lors de la phase 1, ce qui s'avère suffisant compte tenu de la taille du corpus d'empreintes et de la spécificité du domaine.

2.3.3 Estimateur de qualité : CNN léger par modalité, score dans $[0, 1]$

Chaque modalité est munie d'un estimateur de qualité indépendant, implémenté comme un réseau léger à trois couches de convolution. Ces réseaux sont motivés par l'observation, documentée par Soleymani *et al.* [?], selon laquelle la pondération explicite par la qualité à l'étape de fusion améliore le taux d'acceptation de plus de 30% à FAR = 10^{-4} .

Pour le visage, l'estimateur $\mathcal{Q}_f$ prend l'image $\mathbf{x}_f$ en entrée et produit un scalaire

$q_f \in [0, 1]$ par le pipeline suivant :

$$\mathbf{u}_1 = \text{ReLU}(\text{BN}(\text{Conv}_{3 \times 3}^{32}(\mathbf{x}_f))) \in \mathbb{R}^{32 \times 112 \times 112}, \quad (2.6)$$

$$\mathbf{u}_2 = \text{ReLU}(\text{BN}(\text{Conv}_{3 \times 3}^{64}(\mathbf{u}_1))) \in \mathbb{R}^{64 \times 56 \times 56}, \quad (2.7)$$

$$\mathbf{u}_3 = \text{ReLU}(\text{BN}(\text{Conv}_{3 \times 3}^{128}(\mathbf{u}_2))) \in \mathbb{R}^{128 \times 28 \times 28}, \quad (2.8)$$

$$q_f = \sigma(\text{FC}_{512 \rightarrow 1}(\text{GAP}(\mathbf{u}_3))), \quad (2.9)$$

où GAP désigne le *global average pooling*, FC une couche entièrement connectée, et σ la fonction sigmoïde. L'estimateur $\mathcal{Q}_p$ pour les empreintes partage la même structure mais reçoit un canal unique en entrée. Chaque estimateur compte 0,18 M de paramètres. Les scores q_f et q_p sont supervisés indirectement : ils ne requièrent pas d'annotations de qualité explicites mais sont appris de manière faiblement supervisée via la perte composite (§2.8), suivant le principe de DUL [?] selon lequel l'incertitude apprise corrèle naturellement avec la dégradation de la qualité.

2.4 Projecteur Commun et Gestion des Modalités Man-quant

2.4.1 Projecteurs denses avec normalisation L2 : projection sur l'hypersphère unité

Les représentations produites par les encodeurs, $\mathbf{z}_f \in \mathbb{R}^{1408 \times 7 \times 7}$ et $\mathbf{z}_p \in \mathbb{R}^{512 \times 7 \times 7}$, diffèrent à la fois par leur profondeur de canal et leur sémantique interne. Un projecteur commun est requis pour les ramener à un espace partagé où l'attention croisée peut opérer de manière symétrique.

Le projecteur visage $\mathcal{P}_f$ est une séquence de couches entièrement connectées suivie d'une normalisation L2 :

$$\mathbf{h}_f = \frac{\text{ReLU}(\mathbf{W}_{f,2} \cdot \text{ReLU}(\mathbf{W}_{f,1} \cdot \text{Flatten}(\mathbf{z}_f) + \mathbf{b}_{f,1}) + \mathbf{b}_{f,2})}{\|\text{ReLU}(\dots)\|_2}, \quad (2.10)$$

où $\mathbf{W}_{f,1} \in \mathbb{R}^{512 \times (1408 \cdot 49)}$, $\mathbf{W}_{f,2} \in \mathbb{R}^{256 \times 512}$, et $\mathbf{h}_f \in \mathbb{S}^{255} \subset \mathbb{R}^{256}$ vérifie $\|\mathbf{h}_f\|_2 = 1$. Le *flattening* de $\mathbf{z}_f$ produit un vecteur de dimension $1408 \times 7 \times 7 = 69\,032$.

Le projecteur empreinte $\mathcal{P}_p$ suit la même architecture avec des poids distincts :

$$\mathbf{h}_p = \frac{\text{ReLU}(\mathbf{W}_{p,2} \cdot \text{ReLU}(\mathbf{W}_{p,1} \cdot \text{Flatten}(\mathbf{z}_p) + \mathbf{b}_{p,1}) + \mathbf{b}_{p,2})}{\|\text{ReLU}(\dots)\|_2}, \quad (2.11)$$

où $\mathbf{W}_{p,1} \in \mathbb{R}^{512 \times (512 \cdot 49)}$, $\mathbf{W}_{p,2} \in \mathbb{R}^{256 \times 512}$, et $\mathbf{h}_p \in \mathbb{S}^{255}$. La dimension $d = 256$ de l'espace latent commun est choisie comme compromis entre capacité de représentation et com-

plexité computationnelle du transformer ; elle correspond à la dimension utilisée par les architectures biométriques multimodales de l'état de l'art [74, 82].

2.4.2 Token apprenable de remplacement : $\mathbf{t}_{\text{miss}} \in \mathbb{R}^{256}$ paramètre entraînable

La gestion des modalités manquantes constitue un des apports fondamentaux de l'UFM-Transformer. Contrairement aux approches par *fallback* au niveau score [17], qui nécessitent des branches architecturales distinctes, notre méthode opère au niveau du token.

On introduit un vecteur apprenable $\mathbf{t}_{\text{miss}} \in \mathbb{R}^{256}$, initialisé selon une loi normale $\mathcal{N}(\mathbf{0}, 0,02^2 \cdot \mathbf{I})$. Ce token joue le rôle de proxy pour la modalité absente, en s'inspirant des *Cross-Modal Proxy Tokens* (CMPT) proposés par Reza *et al.* [63]. Lorsqu'une modalité est manquante, $\mathbf{t}_{\text{miss}}$ la remplace dans la séquence en entrée du transformer cross-modal, permettant au mécanisme d'attention d'opérer sans modification architecturale.

2.4.3 Mécanisme de remplacement : masque booléen et encodage positionnel

La construction de la séquence d'entrée du transformer repose sur un masque booléen $\mathbf{m} = (m_f, m_p)$ et un encodage positionnel différencié par modalité. On définit la séquence de deux tokens :

$$\mathbf{T} = [\tilde{\mathbf{h}}_f ; \tilde{\mathbf{h}}_p] \in \mathbb{R}^{2 \times 256}, \quad (2.12)$$

où les tokens effectifs sont définis par :

$$\tilde{\mathbf{h}}_k = m_k \cdot \mathbf{h}_k + (1 - m_k) \cdot \mathbf{t}_{\text{miss}}, \quad k \in \{f, p\}. \quad (2.13)$$

Un encodage positionnel apprenable par modalité est ajouté à chaque token. On définit $\mathbf{e}_f, \mathbf{e}_p \in \mathbb{R}^{256}$, initialisés par encodage sinusoïdal standard et affinés pendant l'entraînement. La séquence positionnée est :

$$\mathbf{T}_{\text{pos}} = [\tilde{\mathbf{h}}_f + \mathbf{e}_f ; \tilde{\mathbf{h}}_p + \mathbf{e}_p] \in \mathbb{R}^{2 \times 256}. \quad (2.14)$$

L'entraînement avec *modality dropout* (ModDrop), introduit par Neverova *et al.* [56], renforce la capacité du système à fonctionner avec des modalités incomplètes. Avec une probabilité $p_{\text{drop}} = 0,30$, chaque modalité est aléatoirement masquée pendant l'entraînement. Cette procédure force le transformer à apprendre des corrélations cross-modales robustes tout en préservant la capacité unimodale de dégradation gracieuse.

2.5 Module de Fusion par Attention Croisée Modulée par la Qualité

2.5.1 Attention croisée bidirectionnelle : requêtes visage $\rightarrow$ clés/valeurs empreinte, et inversement

Le module de fusion est un empilement de $L = 4$ couches de transformer à attention croisée. Chaque couche ℓ maintient deux directions d'attention : la visage vers empreinte ($f \rightarrow p$) et l'empreinte vers visage ($p \rightarrow f$).

Soit $\mathbf{T}^{(\ell)} = [\mathbf{t}_f^{(\ell)}; \mathbf{t}_p^{(\ell)}] \in \mathbb{R}^{2 \times 256}$ la séquence en entrée de la couche ℓ , avec $\mathbf{t}_f^{(0)} = \tilde{\mathbf{h}}_f + \mathbf{e}_f$ et $\mathbf{t}_p^{(0)} = \tilde{\mathbf{h}}_p + \mathbf{e}_p$. Pour chaque direction d'attention, on calcule les projections requête, clé et valeur :

$$\mathbf{Q}_f^{(\ell)} = \mathbf{t}_f^{(\ell)} \mathbf{W}_Q^{(\ell,f)}, \quad \mathbf{K}_p^{(\ell)} = \mathbf{t}_p^{(\ell)} \mathbf{W}_K^{(\ell,p)}, \quad \mathbf{V}_p^{(\ell)} = \mathbf{t}_p^{(\ell)} \mathbf{W}_V^{(\ell,p)}, \quad (2.15)$$

$$\mathbf{Q}_p^{(\ell)} = \mathbf{t}_p^{(\ell)} \mathbf{W}_Q^{(\ell,p)}, \quad \mathbf{K}_f^{(\ell)} = \mathbf{t}_f^{(\ell)} \mathbf{W}_K^{(\ell,f)}, \quad \mathbf{V}_f^{(\ell)} = \mathbf{t}_f^{(\ell)} \mathbf{W}_V^{(\ell,f)}, \quad (2.16)$$

où $\mathbf{W}_Q^{(\cdot)}, \mathbf{W}_K^{(\cdot)}, \mathbf{W}_V^{(\cdot)} \in \mathbb{R}^{256 \times 256}$ sont les matrices de projection apprises.

2.5.2 Modulation par qualité : scores d'attention pondérés par $q_f \cdot q_p$

La modulation par qualité constitue le mécanisme central de l'UFM-Transformer. L'observation fondamentale, tirée de l'analyse de l'état de l'art (chapitre 1), est que la modulation de qualité appliquée au niveau score ne peut récupérer aucune information cross-modale perdue lors de l'extraction indépendante des caractéristiques. La modulation doit intervenir au niveau feature pour influencer les interactions cross-modales dès l'apprentissage de la représentation.

Pour chaque tête $h \in \{1, \dots, H\}$ de la direction $f \rightarrow p$, les logits d'attention sont calculés comme :

$$\alpha_{f \rightarrow p}^{(h,\ell)} = \frac{(\mathbf{Q}_f^{(h,\ell)})(\mathbf{K}_p^{(h,\ell)})^\top}{\sqrt{d_h}} + \log(q_f \cdot q_p + \epsilon), \quad (2.17)$$

où $d_h = d/H = 256/8 = 32$ est la dimension par tête, et $\epsilon = 10^{-6}$ évite l'instabilité numérique lorsque $q_f \cdot q_p \approx 0$. Le terme additif $\log(q_f \cdot q_p)$ module les logits : si une modalité est de faible qualité, le produit $q_f \cdot q_p$ est réduit, ce qui abaisse les logits d'attention et donc les poids du *softmax* associé.

Les poids d'attention sont obtenus par :

$$\mathbf{A}_{f \rightarrow p}^{(h,\ell)} = \text{softmax} \left(\frac{\alpha_{f \rightarrow p}^{(h,\ell)}}{\tau} \right) \in \mathbb{R}^{1 \times 1}, \quad (2.18)$$

où $\tau = 1,0$ est la température du *softmax*. L'attention modulée produit le token attendu :

$$\hat{\mathbf{t}}_{f \leftarrow p}^{(h,\ell)} = \mathbf{A}_{f \rightarrow p}^{(h,\ell)} \cdot \mathbf{V}_p^{(h,\ell)} \in \mathbb{R}^{1 \times d_h}. \quad (2.19)$$

La sortie multi-têtes est la concaténation suivie d'une projection linéaire :

$$\text{MHCA}_{f \leftarrow p}^{(\ell)} = \text{Concat}[\hat{\mathbf{t}}_{f \leftarrow p}^{(1,\ell)}, \dots, \hat{\mathbf{t}}_{f \leftarrow p}^{(H,\ell)}] \mathbf{W}_O^{(\ell,f)} \in \mathbb{R}^{1 \times 256}, \quad (2.20)$$

où $\mathbf{W}_O^{(\ell,f)} \in \mathbb{R}^{256 \times 256}$. Le même calcul est effectué pour la direction $p \rightarrow f$.

2.5.3 Masquage pour modalités absentes : attention nulle vers/depuis modalités manquantes

Lorsqu'une modalité est manquante ($m_k = 0$), le token correspondant est $\mathbf{t}_{\text{miss}}$, et le score de qualité est forcé à $q_k = 0$. Dans ce cas, le terme de modulation $\log(q_k + \epsilon)$ devient fortement négatif, ce qui annule pratiquement les poids d'attention dans la direction concernée. Formellement, on applique un masque additif $M_{f \rightarrow p} = -\infty$ si $m_p = 0$, garantissant :

$$\mathbf{A}_{f \rightarrow p}^{(h,\ell)} = 0 \quad \text{si } m_p = 0. \quad (2.21)$$

Cette propriété assure que le système ne produit pas d'attention parasite vers une modalité absente. Lorsque les deux modalités sont présentes, le mécanisme produit une attention croisée complète ; lorsqu'une seule est présente, le transformer se comporte comme un passage avec connexion résiduelle, préservant l'information disponible.

2.5.4 Architecture détaillée : 4 couches, 8 têtes, 256 dimensions

Chaque couche ℓ du transformer cross-modal est structurée selon le schéma pré-normalisation (Pre-LN) suivant :

$$\mathbf{t}_f'^{(\ell)} = \mathbf{t}_f^{(\ell)} + \text{MHCA}_{f \leftarrow p}^{(\ell)}(\text{LN}(\mathbf{t}_f^{(\ell)}), \text{LN}(\mathbf{t}_p^{(\ell)})), \quad (2.22)$$

$$\mathbf{t}_p'^{(\ell)} = \mathbf{t}_p^{(\ell)} + \text{MHCA}_{p \leftarrow f}^{(\ell)}(\text{LN}(\mathbf{t}_p^{(\ell)}), \text{LN}(\mathbf{t}_f^{(\ell)})), \quad (2.23)$$

$$\mathbf{t}_f^{(\ell+1)} = \mathbf{t}_f'^{(\ell)} + \text{FFN}_f^{(\ell)}(\text{LN}(\mathbf{t}_f'^{(\ell)})), \quad (2.24)$$

$$\mathbf{t}_p^{(\ell+1)} = \mathbf{t}_p'^{(\ell)} + \text{FFN}_p^{(\ell)}(\text{LN}(\mathbf{t}_p'^{(\ell)})), \quad (2.25)$$

où LN désigne la normalisation de couche [4], et FFN est le réseau feed-forward à deux couches avec activation GELU et facteur d'expansion 4 :

$$\text{FFN}(\mathbf{x}) = \mathbf{W}_2 \cdot \text{GELU}(\mathbf{W}_1 \cdot \mathbf{x} + \mathbf{b}_1) + \mathbf{b}_2, \quad (2.26)$$

avec $\mathbf{W}_1 \in \mathbb{R}^{1024 \times 256}$ et $\mathbf{W}_2 \in \mathbb{R}^{256 \times 1024}$.

Le token fusionné final, noté $\mathbf{c} \in \mathbb{R}^{256}$, est obtenu par concaténation des tokens de sortie suivie d’une projection linéaire :

$$\mathbf{c} = \mathbf{W}_{\text{fuse}} \cdot \text{Concat}[\mathbf{t}_f^{(L)}, \mathbf{t}_p^{(L)}] + \mathbf{b}_{\text{fuse}}, \quad (2.27)$$

où $\mathbf{W}_{\text{fuse}} \in \mathbb{R}^{256 \times 512}$. Ce token $\mathbf{c}$ constitue la représentation fusionnée bimodale, portant l’information intégrée des deux modalités (ou de la modalité unique disponible, augmentée du proxy token).

Le tableau 2.1 récapitule les hyperparamètres du module d’attention.

TABLE 2.1 – Hyperparamètres du module de fusion par attention croisée

Paramètre	Symbole	Valeur
Nombre de couches	L	4
Nombre de têtes par couche	H	8
Dimension latente	d	256
Dimension par tête	$d_h = d/H$	32
Facteur d’expansion FFN	–	4
Dimension intermédiaire FFN	–	1024
Température softmax	τ	1,0
Epsilon numérique	ϵ	10^{-6}
Taux de dropout (entraînement)	–	0,1

2.5.5 Figure : détail du mécanisme d’attention croisée modulée par qualité

2.5.6 Algorithme : pseudo-code du *forward pass*

L’algorithme 1 formalise le passage avant complet de l’UFM-Transformer. Les dimensions tensorielles sont indiquées en commentaires à chaque étape.

2.6 Tête de Similarité et Tête d’Incertitude

2.6.1 Similarité cosinus avec marge additive ArcFace ($m = 0,5$, $s = 30$)

La tête de similarité calcule le score de correspondance entre le token fusionné $\mathbf{c}$ et les vecteurs de poids des classes. On adopte la formulation ArcFace [15], qui ajoute une marge additive angulaire dans l’espace cosinus pour améliorer la discriminabilité inter-classe.

Soit $\mathbf{W}_j \in \mathbb{R}^{256}$ le vecteur de poids de la classe j (normalisé : $\|\mathbf{W}_j\|_2 = 1$), et $\theta_j =$



FIGURE 2.2 – Détail du mécanisme d’attention croisée modulée par qualité pour une couche. La direction visage $\rightarrow$ empreinte est illustrée ; la direction inverse est symétrique. Le bloc de modulation multiplie les logits d’attention par $\log(q_f \cdot q_p)$ avant le softmax. Le masque booléen **m** force les poids à zéro pour les modalités absentes.

Algorithm 1 Forward pass de l'UFM-Transformer

Image visage $\mathbf{x}_f$ ou $\emptyset$, image empreinte $\mathbf{x}_p$ ou $\emptyset$, masque $\mathbf{m} = (m_f, m_p)$ Score de similarité s , variance d'incertitude σ^2 , scores de qualité (q_f, q_p) # **Module d'encodage** $m_f = 1$ $\mathbf{z}_f \leftarrow \mathcal{E}_f(\mathbf{x}_f) \triangleright \mathbb{R}^{1408 \times 7 \times 7}$ $q_f \leftarrow \mathcal{Q}_f(\mathbf{x}_f) \triangleright [0, 1]$ $\mathbf{z}_f \leftarrow \mathbf{0}$, $q_f \leftarrow 0$ $m_p = 1$ $\mathbf{z}_p \leftarrow \mathcal{E}_p(\mathbf{x}_p) \triangleright \mathbb{R}^{512 \times 7 \times 7}$ $q_p \leftarrow \mathcal{Q}_p(\mathbf{x}_p) \triangleright [0, 1]$ $\mathbf{z}_p \leftarrow \mathbf{0}$, $q_p \leftarrow 0$ # **Projection sur l'hypersphère** $\mathbf{h}_f \leftarrow \mathcal{P}_f(\text{Flatten}(\mathbf{z}_f)) \triangleright \mathbb{S}^{255}$ $\mathbf{h}_p \leftarrow \mathcal{P}_p(\text{Flatten}(\mathbf{z}_p)) \triangleright \mathbb{S}^{255}$ # **Gestion des modalités manquantes** $\tilde{\mathbf{h}}_f \leftarrow m_f \cdot \mathbf{h}_f + (1 - m_f) \cdot \mathbf{t}_{\text{miss}}$ $\tilde{\mathbf{h}}_p \leftarrow m_p \cdot \mathbf{h}_p + (1 - m_p) \cdot \mathbf{t}_{\text{miss}}$ # **Encodage positionnel** $\mathbf{t}_f^{(0)} \leftarrow \tilde{\mathbf{h}}_f + \mathbf{e}_f$, $\mathbf{t}_p^{(0)} \leftarrow \tilde{\mathbf{h}}_p + \mathbf{e}_p \triangleright \mathbb{R}^{2 \times 256}$ # **Transformer cross-modal** $\ell = 0$ $L - 1$ $\mathbf{Q}_f \leftarrow \text{LN}(\mathbf{t}_f^{(\ell)}) \mathbf{W}_Q^{(\ell, f)}$ $\mathbf{K}_p \leftarrow \text{LN}(\mathbf{t}_p^{(\ell)}) \mathbf{W}_K^{(\ell, p)}$ $\mathbf{V}_p \leftarrow \text{LN}(\mathbf{t}_p^{(\ell)}) \mathbf{W}_V^{(\ell, p)}$ $\alpha_{f \rightarrow p} \leftarrow \frac{\mathbf{Q}_f \mathbf{K}_p^\top}{\sqrt{32}} + \log(q_f \cdot q_p + \epsilon)$ $\mathbf{A}_{f \rightarrow p} \leftarrow \text{softmax}(\alpha_{f \rightarrow p}) \triangleright$ Masque nul si $m_p = 0$ $\hat{\mathbf{t}}_f \leftarrow \mathbf{t}_f^{(\ell)} + \mathbf{A}_{f \rightarrow p} \mathbf{V}_p \mathbf{W}_O^{(\ell, f)}$ (direction $p \rightarrow f$ symétrique) $\mathbf{t}_f^{(\ell+1)} \leftarrow \hat{\mathbf{t}}_f + \text{FFN}^{(\ell)}(\text{LN}(\hat{\mathbf{t}}_f))$ $\mathbf{t}_p^{(\ell+1)} \leftarrow \mathbf{t}_p^{(\ell)} + \text{FFN}^{(\ell)}(\text{LN}(\mathbf{t}_p^{(\ell)}))$ # **Token fusionné** $\mathbf{c} \leftarrow \mathbf{W}_{\text{fuse}} \cdot \text{Concat}[\mathbf{t}_f^{(L)}, \mathbf{t}_p^{(L)}] \triangleright \mathbb{R}^{256}$ # **Tête de similarité** $s \leftarrow \mathcal{S}(\mathbf{c}) \triangleright$ Score cosinus avec marge ArcFace # **Tête d'incertitude (MC-Dropout, $K = 5$ passes)** $\{\hat{s}_k\}_{k=1}^K \leftarrow \{\mathcal{U}(\mathbf{c})\}_{k=1}^K \triangleright$ Dropout actif $\bar{s} \leftarrow \frac{1}{K} \sum_k \hat{s}_k$, $\sigma_{\text{tot}}^2 \leftarrow \frac{1}{K} \sum_k (\hat{s}_k - \bar{s})^2$ ($s, \sigma_{\text{tot}}^2, q_f, q_p$)

$\arccos(\mathbf{c} \cdot \mathbf{W}_j / \|\mathbf{c}\|_2)$ l'angle entre $\mathbf{c}$ et $\mathbf{W}_j$. Le logit de la classe j est défini par :

$$\ell_j = s \cdot \cos(\theta_j + m \cdot \mathbb{K}_{[j=y]}), \quad (2.28)$$

où $s = 30$ est le facteur d'échelle, $m = 0,5$ la marge additive, et y l'étiquette de la véritable identité. Le score de similarité binaire entre deux échantillons est le cosinus de leurs tokens fusionnés respectifs :

$$s(\mathbf{c}, \mathbf{c}') = \frac{\mathbf{c} \cdot \mathbf{c}'}{\|\mathbf{c}\|_2 \|\mathbf{c}'\|_2}. \quad (2.29)$$

Le choix de $s = 30$ et $m = 0,5$ est conforme aux valeurs standard de la littérature sur la reconnaissance faciale [15] et a été validé empiriquement sur notre corpus de validation. La marge $m = 0,5$ correspond à un écart angulaire d'environ $28,6^\circ$, suffisant pour renforcer la séparabilité sans provoquer de sous-apprentissage.

2.6.2 Tête d'incertitude : 5 passes avant avec dropout actif

La quantification de l'incertitude repose sur le Monte Carlo Dropout (MC-Dropout), introduit par Gal & Ghahramani [20]. Cette méthode interprète le dropout comme une approximation variationnelle de l'inférence bayésienne, sans nécessiter de modification architecturale. La tête d'incertitude $\mathcal{U}$ est constituée de deux couches entièrement connectées de $256 \rightarrow 128 \rightarrow 1$ neurones, avec activation ReLU intermédiaire et dropout $p = 0,2$ entre les couches.

À l'inférence, $K = 5$ passes avant sont effectuées avec le dropout actif, produisant un

ensemble de prédictions $\{\hat{s}_k\}_{k=1}^K$. La moyenne et la variance empiriques sont calculées :

$$\bar{s} = \frac{1}{K} \sum_{k=1}^K \hat{s}_k, \quad (2.30)$$

$$\sigma_{\text{tot}}^2 = \frac{1}{K} \sum_{k=1}^K (\hat{s}_k - \bar{s})^2. \quad (2.31)$$

2.6.3 Décomposition aléatoire vs épistémique

Suivant la taxonomie de Kendall & Gal [37], l'incertitude totale se décompose en deux composantes distinctes. L'incertitude aléatoire (ou *aleatoric*) provient du bruit inhérent aux données — flou de l'image, occlusion partielle, bruit de capteur. L'incertitude épistémique (ou *epistemic*) reflète l'ignorance du modèle, c'est-à-dire les zones de l'espace d'entrée insuffisamment couvertes par les données d'entraînement.

Lorsque les deux modalités sont présentes, l'incertitude aléatoire est estimée par la variance des prédictions sous la même entrée, là où le modèle est certain de ses poids mais les données sont bruitées. L'incertitude épistémique est estimée par la variance inter-passes, qui capture le désaccord du modèle sur ses propres paramètres. Formellement :

$$\sigma_{\text{alea}}^2 = \mathbb{E}_{\omega} [\text{Var}(s \mid \mathbf{x}, \omega)], \quad (2.32)$$

$$\sigma_{\text{epis}}^2 = \text{Var}_{\omega} [\mathbb{E}(s \mid \mathbf{x}, \omega)], \quad (2.33)$$

où ω désigne les paramètres du réseau. L'incertitude totale vérifie la décomposition de la loi de la variance totale : $\sigma_{\text{tot}}^2 = \sigma_{\text{alea}}^2 + \sigma_{\text{epis}}^2$.

2.6.4 Intervalle de confiance et option de rejet

Le score de similarité s et sa variance σ_{tot}^2 permettent de construire un intervalle de confiance à 95% pour la décision :

$$\text{IC}_{95\%}(s) = [\bar{s} - 1,96 \cdot \sigma_{\text{tot}}, \bar{s} + 1,96 \cdot \sigma_{\text{tot}}]. \quad (2.34)$$

Le système peut émettre une option de rejet (*reject option*) lorsque l'incertitude excède un seuil prédéfini σ_{max}^2 . Cette fonctionnalité, alignée sur le principe de la prédiction conforme [6], permet d'abstention de décider lorsque la confiance est insuffisante :

$$\text{décision} = \begin{cases} \text{génuin} & \text{si } \bar{s} > \tau \text{ et } \sigma_{\text{tot}}^2 < \sigma_{\text{max}}^2, \\ \text{imposteur} & \text{si } \bar{s} \leq \tau \text{ et } \sigma_{\text{tot}}^2 < \sigma_{\text{max}}^2, \\ \text{rejet ("ne sait pas")} & \text{si } \sigma_{\text{tot}}^2 \geq \sigma_{\text{max}}^2. \end{cases} \quad (2.35)$$

La valeur de $\sigma_{\max}^2$ est calibrée sur l'ensemble de validation pour obtenir un taux de rejet cible de 5% sur les paires d'identités connues.

2.7 Mécanismes d'Explicabilité

2.7.1 Visualisation des cartes d'attention cross-modale

L'attention croisée constitue une source d'explicabilité inhérente à l'architecture. Les poids $\mathbf{A}_{f \rightarrow p}^{(h,\ell)}$ et $\mathbf{A}_{p \rightarrow f}^{(h,\ell)}$ révèlent, pour chaque paire de tokens, l'importance relative accordée à la modalité complémentaire. Cette propriété double usage — fusion et explication — n'a pas été exploitée dans les systèmes biométriques multimodaux précédents [66, 82].

Pour chaque couche ℓ et chaque tête h , on visualise la matrice d'attention $\mathbf{A}^{(h,\ell)} \in \mathbb{R}^{2 \times 2}$ comme un graphe bipartite où les nœuds représentent les tokens visage et empreinte, et les arêtes pondérées indiquent les forces d'attention. L'agrégation sur toutes les têtes et couches, pondérée par l'écart-type de chaque tête (critère de sélectivité), fournit une mesure globale de la contribution cross-modale :

$$\bar{\mathbf{A}} = \sum_{\ell=1}^L \sum_{h=1}^H w_h \cdot \mathbf{A}^{(h,\ell)}, \quad w_h = \frac{\sigma(\mathbf{A}^{(h,\cdot)})}{\sum_{h'} \sigma(\mathbf{A}^{(h',\cdot)})}. \quad (2.36)$$

2.7.2 Grad-CAM bimodal : régions faciales et minuties d'empreinte

Pour localiser les régions discriminantes au niveau pixel, on combine la visualisation d'attention avec Grad-CAM [?]. Pour le visage, on calcule la carte de saillance $\mathbf{M}_f \in \mathbb{R}^{7 \times 7}$ en rétro-propageant le gradient du score de similarité s jusqu'à la carte de caractéristiques $\mathbf{z}_f$:

$$\mathbf{M}_f = \text{ReLU} \left(\sum_{c=1}^{1408} w_c^{(f)} \cdot \mathbf{z}_{f,c} \right), \quad w_c^{(f)} = \frac{1}{7 \times 7} \sum_{i,j} \frac{\partial s}{\partial \mathbf{z}_{f,c}^{(i,j)}}. \quad (2.37)$$

La carte est ensuite interpolée à la résolution originale 224×224 par bilinéaire et superposée à l'image faciale.

Pour l'empreinte, le même calcul produit $\mathbf{M}_p \in \mathbb{R}^{7 \times 7}$. L'alignement spontané des cartes d'attention ViT avec les régions riches en minuties (IoU = $0,41 \pm 0,07$), documenté par Gazi *et al.* [21], garantit que les zones de forte saillance correspondent aux structures papillaires discriminantes.

La figure 2.3 illustre un exemple de visualisation bimodale complète, où les régions faciales chaudes (yeux, nez, mâchoire) sont confrontées aux zones d'empreinte actives (minuties, noyaux, deltas), avec les poids d'attention cross-modale indiquant la correspondance.



FIGURE 2.3 – Visualisation bimodale de l’explicabilité. À gauche : carte Grad-CAM superposée à l’image faciale, avec les régions chaudes indiquant les zones contributives. Au centre : carte d’attention de l’empreinte alignée sur les minuties. À droite : graphe bipartite des poids d’attention cross-modale entre les deux représentations.

2.7.3 Analyse des cas d'échec par attention

Les cartes d'attention permettent également d'analyser les cas d'erreur. Une fausse acceptation (*false accept*) se produit lorsque le score s excède le seuil τ pour une paire d'identités différentes. La visualisation des poids d'attention révèle alors si l'erreur provient d'une sur-attention à une zone non discriminante (par exemple, le fond de l'image visage) ou d'une similarité fortuite entre des minuties d'empreintes de doigts différents. Cette capacité de diagnostic post-hoc, héritée des travaux de Lu *et al.* [46] sur CorrRISE, est ici intégrée de manière inhérente à l'architecture, sans nécessiter de méthode post-hoc externe.

2.8 Fonction de Perte et Stratégie d'Entraînement

2.8.1 Perte composite : triplet + ArcFace + régularisation d'incertitude

L'apprentissage de l'UFM-Transformer repose sur une fonction de perte composite combinant trois objectifs complémentaires :

$$\mathcal{L}_{\text{total}} = \mathcal{L}_{\text{ArcFace}} + \lambda_{\text{triplet}} \cdot \mathcal{L}_{\text{triplet}} + \lambda_{\sigma} \cdot \mathcal{L}_{\sigma}, \quad (2.38)$$

avec $\lambda_{\text{triplet}} = 0,5$ et $\lambda_{\sigma} = 0,1$.

La perte ArcFace, déjà introduite en §2.6, est la composante principale de supervision identitaire. Pour un batch de B échantillons avec leurs étiquettes $\{y_b\}_{b=1}^B$, elle s'écrit :

$$\mathcal{L}_{\text{ArcFace}} = -\frac{1}{B} \sum_{b=1}^B \log \frac{e^{s \cdot \cos(\theta_{y_b} + m)}}{e^{s \cdot \cos(\theta_{y_b} + m)} + \sum_{j \neq y_b} e^{s \cdot \cos(\theta_j)}}. \quad (2.39)$$

La perte triplet renforce la séparabilité des paires dans l'espace latent. Pour un ancêtre $\mathbf{c}_a$, un positif $\mathbf{c}_p$ (même identité) et un négatif $\mathbf{c}_n$ (identité différente), elle s'écrit :

$$\mathcal{L}_{\text{triplet}} = \frac{1}{B} \sum_{b=1}^B \max(0, \|\mathbf{c}_a - \mathbf{c}_p\|_2^2 - \|\mathbf{c}_a - \mathbf{c}_n\|_2^2 +), \quad (2.40)$$

où $= 0,3$ est la marge de séparation. Les triplets sont échantillonnés selon la stratégie *semi-hard negative mining* : pour chaque ancre, on sélectionne un négatif vérifiant $\|\mathbf{c}_a - \mathbf{c}_n\|_2^2 < \|\mathbf{c}_a - \mathbf{c}_p\|_2^2 +$ mais dont la distance reste supérieure à celle du positif.

La régularisation d'incertitude encadre la variance prédite par la tête $\mathcal{U}$. Inspirée par Chang *et al.* [?], elle pénalise les prédictions de forte incertitude sur les échantillons bien

classés, tout en autorisant une variance élevée sur les échantillons difficiles :

$$\mathcal{L}_\sigma = \frac{1}{B} \sum_{b=1}^B \left| \sigma_{\text{tot},b}^2 - \gamma \cdot \mathbb{I}_{[s_b, y_b < \tau]} \right|, \quad (2.41)$$

où $\gamma = 0,5$ est la variance cible pour les échantillons mal classés. Cette formulation encourage le modèle à produire une incertitude élevée lorsque la décision est erronée, et une incertitude faible lorsque la décision est correcte.

2.8.2 Phase 1 : pré-entraînement unimodal (50 époques, ArcFace seul)

L'entraînement procède en deux phases. La phase 1 pré-entraîne les encodeurs unimodaux de manière indépendante. L'objectif est de fournir à chaque branche une représentation discriminante avant l'apprentissage conjoint.

Encodeur visage. L'EfficientNet-B2 pré-entraîné sur ImageNet est décongelé progressivement. Seules les trois derniers blocs sont entraînés pendant les 30 premières époques, puis l'ensemble du réseau est affiné sur les 20 époques suivantes. Le projecteur $\mathcal{P}_f$ et la tête ArcFace sont entraînés conjointement avec la perte $\mathcal{L}_{\text{ArcFace}}$ seule. Le batch contient $B = 64$ images de $N = 16$ identités différentes (4 images par identité).

Encodeur empreinte. Le CNN résiduel $\mathcal{E}_p$ est entraîné *from scratch* avec le même protocole. Le batch contient $B = 64$ images de $N = 16$ identités. Les augmentations appliquées sont : rotation aléatoire $\mathcal{U}[-15^\circ, +15^\circ]$, ajustement de contraste $\mathcal{U}[0,8, 1,2]$, et ajout de bruit gaussien $\mathcal{N}(0, 0,01^2)$.

Estimateurs de qualité. Les estimateurs $\mathcal{Q}_f$ et $\mathcal{Q}_p$ sont entraînés conjointement avec leurs encodeurs respectifs, supervisés indirectement par la perte ArcFace. L'hypothèse sous-jacente est que la qualité apprise doit corrélérer avec la difficulté de classification, un principe validé par les travaux sur DUL [?] et CR-FIQA [8].

2.8.3 Phase 2 : fine-tuning joint (100 époques, dropout modalités 30%, perte complète)

La phase 2 assemble l'architecture complète et entraîne tous les modules conjointement avec la perte composite (2.38). Les hyperparamètres de cette phase sont résumés dans le tableau 2.2.

La planification du taux d'apprentissage suit un profil de cosinus avec période de chauffe (*warm-up*) :

$$\eta(t) = \begin{cases} \eta_0 \cdot \frac{t}{T_{\text{warm}}} & \text{si } t < T_{\text{warm}}, \\ \eta_{\min} + \frac{1}{2}(\eta_0 - \eta_{\min}) \left(1 + \cos \left(\frac{t - T_{\text{warm}}}{T_{\max} - T_{\text{warm}}} \pi \right) \right) & \text{sinon,} \end{cases} \quad (2.42)$$

TABLE 2.2 – Hyperparamètres de la phase 2 d’entraînement (fine-tuning joint)

Paramètre	Symbole	Valeur
Nombre d’époques	–	100
Taille du batch	B	128
Identités par batch	N	32
Échantillons par identité	–	4
Optimiseur	–	AdamW [?]
Taux d’apprentissage initial	η_0	10^{-4}
Taux d’apprentissage (backbones)	η_{back}	10^{-5}
Poids décroissance	β_1, β_2	0,9, 0,999
Décroissance de régularisation	λ_{WD}	10^{-2}
Planification	–	Cosine annealing avec warm-up
Époques de warm-up	–	10
Gradient clipping	–	$\ \mathbf{g}\ _2 \leq 1,0$
Dropout modalités (ModDrop)	p_{drop}	0,30
Dropout interne	–	0,10

où $T_{\text{warm}} = 10$ époques, $T_{\text{max}} = 100$ époques, et $\eta_{\text{min}} = 10^{-6}$. Le gradient clipping à $\|\mathbf{g}\|_2 \leq 1,0$ stabilise l’entraînement du transformer, particulièrement lorsque le dropout modalité génère des configurations d’entrée inhabituelles.

2.8.4 Optimisation : AdamW, cosine annealing, gradient clipping

L’optimiseur AdamW [?] est préféré à Adam standard car il découple la décroissance de poids (*weight decay*) de la mise à jour du gradient de momentum. Cette propriété s’avère essentielle pour le transformer cross-modal, où les matrices d’attention requièrent une régularisation différenciée des couches feed-forward. La décroissance de poids $\lambda_{\text{WD}} = 10^{-2}$ est appliquée à l’ensemble des paramètres exceptés les biais et les termes de normalisation de couche.

2.8.5 Algorithme : boucle d’entraînement complète avec deux phases

L’algorithme 2 présente la boucle d’entraînement complète. Les deux phases y sont explicitées avec leurs conditions respectives.

Le nombre total de paramètres entraînaibles de l’UFM-Transformer est de **XX,X M**. Les encodeurs $\mathcal{E}_f$ et $\mathcal{E}_p$ concentrent la majorité de la capacité (respectivement 9,2 M et 11,2 M de paramètres), tandis que le module de fusion transformer ajoute seulement **X,X M** de paramètres supplémentaires, ce qui en fait une solution compacte au regard des architectures transformer biométriques récentes [24, 74].

Ce chapitre a exposé l’intégralité de l’architecture UFM-Transformer, depuis la formulation mathématique du problème jusqu’à la boucle d’entraînement complète. Chaque

Algorithm 2 Boucle d'entraînement complète de l'UFM-Transformer

Données d'entraînement $\mathcal{D} = \{(\mathbf{x}_f^{(i)}, \mathbf{x}_p^{(i)}, y^{(i)})\}$, hyperparamètres Paramètres entraînés θ^* — **Phase 1 : Pré-entraînement unimodal** — Initialiser $\mathcal{E}_f$ depuis ImageNet, $\mathcal{E}_p$ aléatoirement Initialiser $\mathcal{Q}_f, \mathcal{Q}_p, \mathcal{P}_f, \mathcal{P}_p$, têtes ArcFace époque = 1 50 # **Branche visage** each batch $(\mathbf{x}_f, y) \sim \mathcal{D}_f$ $\mathbf{z}_f \leftarrow \mathcal{E}_f(\mathbf{x}_f)$ $\mathbf{h}_f \leftarrow \mathcal{P}_f(\text{Flatten}(\mathbf{z}_f))$ $\mathcal{L} \leftarrow \mathcal{L}_{\text{ArcFace}}(\mathbf{h}_f, y)$ Rétro-propagation et mise à jour AdamW($\eta = 10^{-4}$) # **Branche empreinte** each batch $(\mathbf{x}_p, y) \sim \mathcal{D}_p$ $\mathbf{z}_p \leftarrow \mathcal{E}_p(\mathbf{x}_p)$ $\mathbf{h}_p \leftarrow \mathcal{P}_p(\text{Flatten}(\mathbf{z}_p))$ $\mathcal{L} \leftarrow \mathcal{L}_{\text{ArcFace}}(\mathbf{h}_p, y)$ Rétro-propagation et mise à jour AdamW($\eta = 10^{-4}$) — **Phase 2 : Fine-tuning joint** — Assembler l'architecture complète : $\mathcal{E}_f, \mathcal{E}_p, \mathcal{Q}_f, \mathcal{Q}_p, \mathcal{P}_f, \mathcal{P}_p$, transformer, têtes Initialiser $\mathbf{t}_{\text{miss}} \sim \mathcal{N}(\mathbf{0}, 0,02^2 \cdot \mathbf{I})$ époque = 1 100 $\eta \leftarrow \text{CosineSchedule}(\text{époque}, \eta_0 = 10^{-4}, T_{\text{warm}} = 10)$ each batch $(\mathbf{x}_f, \mathbf{x}_p, y) \sim \mathcal{D}$ # **Modality dropout** $b = 1 \ B$ Tirage $u_f, u_p \sim \mathcal{U}[0, 1]$ $m_f^{(b)} \leftarrow \mathbb{1}_{[u_f > p_{\text{drop}}]}$, $m_p^{(b)} \leftarrow \mathbb{1}_{[u_p > p_{\text{drop}}]}$ Si $m_f^{(b)} = m_p^{(b)} = 0$: forcer $m_f^{(b)} \leftarrow 1$ (au moins une modalité) $(s, \sigma^2, q_f, q_p) \leftarrow \text{UFM-Forward}(\mathbf{x}_f, \mathbf{x}_p, \mathbf{m})$ # **Perte composite** $\mathcal{L} \leftarrow \mathcal{L}_{\text{ArcFace}} + 0,5 \cdot \mathcal{L}_{\text{triplet}} + 0,1 \cdot \mathcal{L}_{\sigma}$ Rétro-propagation $\mathbf{g} \leftarrow \text{clip}_{\text{norm}}(\mathbf{g}, 1, 0)$ Mise à jour AdamW($\eta, \lambda_{\text{WD}} = 10^{-2}$) # **Validation** Évaluer TAR@FAR= 10^{-4} , EER, AUC sur ensemble de validation Sauvegarder meilleur modèle selon TAR@FAR= 10^{-4} $\theta^* \leftarrow$ meilleurs paramètres sur validation

module a été justifié par rapport aux travaux antérieurs, et les hyperparamètres critiques ont été explicités avec leurs valeurs. Le chapitre suivant procède à l'évaluation empirique de cette architecture sur les corpus biométriques de référence.

Chapitre 3

Expérimentations et Résultats

Ce chapitre présente l'évaluation exhaustive du modèle UFM-Transformer proposé au Chapitre 2. La démarche expérimentale vise à répondre aux trois questions de recherche formulées dans l'introduction : (QR1) l'attention croisée modulée par qualité atteint-elle des performances de vérification biométrique comparables ou supérieures aux méthodes multimodales de référence ? (QR2) le mécanisme d'incertitude améliore-t-il significativement la robustesse en conditions dégradées et la calibration des scores ? (QR3) l'architecture conjointe visage-empreinte autorise-t-elle une explicabilité pertinente des décisions biométriques ? L'évaluation s'appuie sur un protocole rigoureux, incluant un split sujet-disjoint, dix conditions de dégradation, cinq méthodes de référence et un panel de métriques couvrant la performance, la calibration et l'efficacité computationnelle.

3.1 Protocole Expérimental

3.1.1 Dataset Multimodal Biometrics Dataset

Les expérimentations ont été conduites sur le *Multimodal Biometrics Dataset* (MBD) disponible sur Kaggle¹. Ce dataset rassemble des échantillons biométriques de 100 sujets distincts, chacun étant représenté par au moins cinq captures par modalité (visage et empreinte digitale). Les images de visage présentent une résolution native de 512×512 pixels, acquises dans des conditions d'éclairage contrôlé mais variables ; les empreintes digitales sont fournies à une résolution de 512×512 pixels sous forme d'images en niveaux de gris codant le relief papillaire.

Ce jeu de données présente plusieurs caractéristiques justifiant son adoption pour l'évaluation. La distribution démographique des sujets — bien que non explicitement annotée en genre et âge — reflète une diversité suffisante pour limiter les biais de population. Le nombre d'échantillons par sujet (≥ 5) autorise une partition en ensembles d'entraînement, de validation et de test tout en maintenant une marge d'augmentation raisonnable. Le cou-

1. <https://www.kaggle.com/datasets>

plage natif des deux modalités pour chaque sujet garantit l’alignement des paires positives (même identité, deux modalités) et des paires négatives (identités distinctes), condition essentielle à l’apprentissage métrique en vérification biométrique. Enfin, la disponibilité publique du dataset permet la répliquabilité des résultats présentés ci-après.

3.1.2 Prétraitement et Stratification des Données

La préparation des données suit un pipeline rigoureux. Chaque image de visage est redimensionnée à 224×224 pixels, normalisée par les moyennes et écarts-types du dataset ImageNet ($\mu = [0.485, 0.456, 0.406]$, $\sigma = [0.229, 0.224, 0.225]$), puis convertie en espace RGB. Les empreintes digitales, initialement en niveaux de gris, sont répliquées sur trois canaux pour compatibilité avec les dorsaux pré-entraînés sur ImageNet, avec une normalisation identique.

La stratification adopte un split sujet-disjoint de proportion 70 / 15 / 15 : 70 sujets constituent l’ensemble d’entraînement, 15 l’ensemble de validation et 15 l’ensemble de test. Cette partition garantit que les identités présentes en phase de test sont inconnues du modèle durant l’entraînement, reproduisant ainsi les conditions réelles de déploiement (open-set verification). L’absence de fuite d’information entre les sous-ensembles a été vérifiée par un contrôle d’unicité des identifiants sujets.

3.1.3 Augmentations de Données et Simulation de Dégradations

Durant la phase d’entraînement, un ensemble d’augmentations géométriques et photométriques est appliqué aléatoirement : retournement horizontal ($p = 0.5$), rotation dans l’intervalle $[-10^\circ, +10^\circ]$, légère modification de luminosité et de contraste (facteurs dans $[0.8, 1.2]$), et bruit gaussien additif ($\sigma \in [0, 0.01]$). Ces augmentations visent à améliorer la généralisation sans altérer la sémantique biométrique de l’identité.

La robustesse du modèle est évaluée au travers de dix conditions de dégradation spécifiques, simulées algorithmiquement sur l’ensemble de test :

1. **Bruit gaussien** ($\sigma = 0.05$) : dégradation photométrique modélisant les capteurs de faible qualité.
2. **Bruit gaussien fort** ($\sigma = 0.10$) : condition extrême de bruit.
3. **Flou gaussien** (noyau 5×5 , $\sigma = 2.0$) : défocalisation du capteur.
4. **Flou de mouvement** (noyau 7×7 , direction aléatoire) : sujet en mouvement lors de l’acquisition.
5. **Compression JPEG** (qualité = 30) : artefacts de compression, courants en transmission.
6. **Sous-exposition** (facteur $\gamma = 0.5$) : scènes sous-éclairées.

7. **Sur-exposition** (facteur $\gamma = 2.0$) : saturation des zones claires.
8. **Occlusion partielle** (masque rectangulaire couvrant 20% de l'image) : obstruction partielle du sujet.
9. **Baisse de résolution** (facteur 0.5 puis upsampling) : capteurs de résolution réduite.
10. **Combinaison** (bruit $\sigma = 0.03$ + flou 3×3 + JPEG 50) : dégradation multiple.

Ces conditions ont été appliquées indépendamment aux modalités visage et empreinte, permettant une analyse fine de la sensibilité de chaque méthode.

3.1.4 Environnement Logiciel et Matériel

L'implémentation a été réalisée en PyTorch 2.0 avec prise en charge de la compilation JIT. L'entraînement a été effectué sur une GPU NVIDIA A100 (80 Go HBM2e). Le processus d'optimisation repose sur AdamW avec un taux d'apprentissage initial de 10^{-4} , un décroissement cosmique sur 100 époques pour la phase d'entraînement des extracteurs, puis 50 époques pour la phase d'affinage du fusionneur. La taille de batch est fixée à 64 (32 paires positives, 32 paires négatives). La régularisation L2 ($\lambda = 10^{-4}$) et un dropout de 0.1 sont appliqués systématiquement. Le MC Dropout est activé avec $T = 20$ passes forward pour l'estimation de l'incertitude en phase d'inférence. La stratégie de curriculum learning doux a été adoptée : les premières 20 époques exploitent uniquement les échantillons de haute qualité, avant d'intégrer progressivement les dégradations, ce qui stabilise l'apprentissage des mécanismes de qualité. Toutes les expériences ont été conduites avec une graine aléatoire fixée ($seed = 42$) pour garantir la reproductibilité des résultats. Les métriques rapportées correspondent à la moyenne de cinq exécutions indépendantes, l'écart-type associé quantifiant la variabilité liée à l'initialisation. L'ensemble du code, les configurations d'entraînement et les poids du modèle sont rendus disponibles publiquement à des fins de répliquabilité.

3.2 Métriques d'Évaluation

3.2.1 Métriques de Performance en Vérification Biométrique

L'évaluation des performances repose sur les métriques canoniques de la littérature biométrique. Le **Equal Error Rate** (EER) correspond au point de fonctionnement où le False Match Rate (FMR) égale le False Non-Match Rate (FNMR). Il constitue une métrique synthétique privilégiée pour la comparaison inter-systèmes. Le **True Acceptance Rate** (TAR) mesuré à des seuils de FMR fixés — TAR@FAR= 0.1% et TAR@FAR= 1% — reflète la capacité opérationnelle du système dans des régimes de sécurité exigeants.

L’**Aire Sous la Courbe ROC** (AUC) quantifie la séparabilité globale entre distributions de scores intra-classe et inter-classe.

Le choix du TAR à FAR = 0.1% comme métrique principale relève de la pratique opérationnelle en biométrie à haute sécurité : les systèmes de contrôle d’accès aux infrastructures critiques fonctionnent typiquement à de tels seuils, où chaque dixième de point de pourcentage gagné se traduit par une réduction substantielle des fausses acceptations. Le FMR et le FNMR sont définis comme suit :

$$\text{FMR}(\tau) = \frac{|\{(i, j) : s_{ij} \geq \tau, y_{ij} = 0\}|}{|\{(i, j) : y_{ij} = 0\}|}, \quad \text{FNMR}(\tau) = \frac{|\{(i, j) : s_{ij} < \tau, y_{ij} = 1\}|}{|\{(i, j) : y_{ij} = 1\}|} \quad (3.1)$$

où s_{ij} désigne le score de similarité entre les échantillons i et j , et $y_{ij} \in \{0, 1\}$ l’étiquette de correspondance.

3.2.2 Métriques de Calibration

La calibration évalue l’adéquation entre la confiance prédite par le modèle et la probabilité réelle de succès. L’**Expected Calibration Error** (ECE) discrétise l’intervalle de confiance en M bacs ($M = 15$ dans nos expériences) et mesure l’écart moyen pondéré :

$$\text{ECE} = \sum_{m=1}^M \frac{|B_m|}{N} |\text{acc}(B_m) - \text{conf}(B_m)| \quad (3.2)$$

où $\text{acc}(B_m)$ est la précision empirique et $\text{conf}(B_m)$ la confiance moyenne dans le bac B_m . Le **Maximum Calibration Error** (MCE) retient l’écart maximal sur l’ensemble des bacs, mettant en lumière les zones de mauvaise calibration :

$$\text{MCE} = \max_{m \in \{1, \dots, M\}} |\text{acc}(B_m) - \text{conf}(B_m)| \quad (3.3)$$

Ces métriques sont particulièrement pertinentes dans le cadre biométrique : un système bien calibré permet de fixer des seuils opérationnels avec une garantie probabiliste sur le taux d’erreur, condition nécessaire à l’intégration dans des chaînes de décision critiques. Un modèle présentant une ECE élevée surestime systématiquement sa confiance, ce qui conduit les opérateurs à fixer des seuils trop permisifs ou, inversement, à appliquer des marges de sécurité arbitraires qui dégradent l’expérience utilisateur. L’ECE et le MCE fournissent des outils quantitatifs pour auditer ce comportement avant déploiement.

3.2.3 Métriques d’Efficacité Computationnelle

Outre la précision, l’adéquation du modèle au déploiement embarqué est évaluée au travers de trois indicateurs. Le nombre de paramètres entraînaables (Params) conditionne l’empreinte mémoire. Le nombre d’opérations en virgule flottante (FLOPS) mesure la

charge computationnelle d’une inférence forward. Le temps d’inférence moyen par paire de comparaison, mesuré sur GPU NVIDIA A100 avec batch de taille 1 (condition représentative du déploiement temps réel), caractérise la latence opérationnelle. Ces métriques sont rapportées pour chaque méthode afin de quantifier le compromis précision-efficacité.

3.3 Résultats Principaux

3.3.1 Comparaison avec les Méthodes de Référence

Le Tableau 3.1 présente les performances de UFM-Transformer confrontées à cinq approches de référence représentatives de l’état de l’art en biométrie multimodale.

TABLE 3.1 – Comparaison des performances de vérification biométrique. TAR rapporté à deux seuils opérationnels ($FAR = 0.1\%$ et $FAR = 1\%$). Meilleurs résultats en gras.

Méthode	EER (%)	TAR@0.1%	TAR@1%	AUC (%)	Params (M)
ResNet-18 (visage seul)	XX,XX	XX,XX	XX,XX	XX,XX	11.2
ResNet-18 (empreinte seule)	XX,XX	XX,XX	XX,XX	XX,XX	11.2
Concaténation + MLP	XX,XX	XX,XX	XX,XX	XX,XX	24.4
Cross-Attention Transformer	XX,XX	XX,XX	XX,XX	XX,XX	28.1
DenseNet-Fusion [31]	XX,XX	XX,XX	XX,XX	XX,XX	22.8
UFM-Transformer (proposé)	XX,XX	XX,XX	XX,XX	XX,XX	27.6

La fusion multimodale par simple concaténation des descripteurs suivie d’un MLP à deux couches améliore sensiblement les approches unimodales, confirmant l’apport intrinsèque de la complémentarité visage-empreinte. Néanmoins, cette stratégie reste inférieure aux méthodes intégrant un mécanisme d’interaction explicite entre modalités. L’architecture *Cross-Attention Transformer* — sans modulation par qualité ni gestion de l’incertitude — constitue la référence la plus concurrente. UFM-Transformer dépasse cette dernière, réduisant l’EER relatif de **XX,XX%** et améliorant le TAR@0.1% de **XX,XX%** absolus. Cette avance se concentre principalement dans le régime à faible FAR, où la sélectivité de l’attention modulée par qualité et la modélisation de l’incertitude par MC Dropout se révèlent décisives pour discriminer les paires ambiguës. L’écart d’AUC, bien que plus modeste, confirme une séparabilité globale supérieure.

3.3.2 Courbes ROC et DET

La Figure 3.1 juxtapose les courbes ROC (Receiver Operating Characteristic) et DET (Detection Error Tradeoff) pour l’ensemble des méthodes évaluées.

L’analyse des courbes ROC révèle que l’écart entre UFM-Transformer et les approches de référence s’accroît dans la région à faible taux de fausses acceptances ($FAR < 0.1\%$), zone critique pour les applications à haute sécurité. Les courbes DET, qui représentent




FIGURE 3.1 – (Gauche) Courbes ROC comparatives. UFM-Transformer domine dans la région à faible FAR. (Droite) Courbes DET ; les axes logarithmiques révèlent l’avantage accru dans le régime de sécurité élevée ($\text{FAR} < 0.1\%$).

le FNMR en fonction du FMR sur des échelles logarithmiques normales déviées, mettent en évidence cette même dominance avec une meilleure lisibilité dans le régime opérationnel. La courbe DET de UFM-Transformer se situe systématiquement en dessous de celles des baselines, traduisant un meilleur compromis FNMR-FMR quel que soit le seuil opérationnel retenu.

L’inspection visuelle des courbes ROC suggère également que les méthodes unimodales présentent une aire sous la courbe globalement inférieure, avec une décroissance rapide dès que le FAR devient inférieur à 0.01% . Cette fragilité dans le régime à haute sécurité disqualifie les approches visage seul ou empreinte seule pour les applications critiques, confirmant l’intuition selon laquelle la fusion multimodale constitue une nécessité opérationnelle plutôt qu’une simple amélioration incrémentale. Les courbes DET confirment ce constat avec une netteté accrue : à $\text{FAR} = 0.001\%$, UFM-Transformer affiche un FNMR de **XX,XX**% contre **XX,XX**% pour sa baseline la plus proche, écart de **XX,XX**% absolu qui se traduirait par des milliers de fausses rejections évitées quotidiennement dans un aéroport de grande capacité.

3.3.3 Distribution des Scores de Similarité

La Figure 3.2 illustre les distributions des scores de similarité pour les paires intra-classe (mêmes identités) et inter-classe (identités distinctes), obtenues avec UFM-Transformer sur l’ensemble de test.

Les diagrammes en violon mettent en évidence deux distributions quasiment disjointes, avec une zone de chevauchement restreinte. Cette séparation explique l’EER faible observé




FIGURE 3.2 – Diagrammes en violon des scores de similarité UFM-Transformer. (Haut) Scores intra-classe (paires positives). (Bas) Scores inter-classe (paires négatives). La séparation des distributions conditionne l'EER et le TAR opérationnel.

au Tableau 3.1. La distribution des scores positifs présente une médiane élevée (**XX,XX**) avec une faible dispersion interquartile, tandis que celle des scores négatives se concentre dans les valeurs basses avec quelques valeurs aberrantes — correspondant aux cas où des sujets différents présentent une ressemblance fortuite élevée. Ces outliers constituent précisément les cas où le mécanisme d’incertitude apporte le plus de valeur, en signalant une confiance réduite susceptible de déclencher une vérification humaine.

3.4 Analyse de Robustesse

3.4.1 Résultats sous Dégradations Contrôlées

Le Tableau 3.2 rapporte l’EER de chaque méthode sous les dix conditions de dégradation définies en Section 3.1. Pour chaque condition, les dégradations sont appliquées aux deux modalités simultanément, sauf indication contraire.

TABLE 3.2 – EER (%) sous dix conditions de dégradation. Best et Second-best en gras et italique. U = UFM-Transformer, C = Concaténation, A = Cross-Attention, D = DenseNet-Fusion, V = ResNet-18 visage, E = ResNet-18 empreinte.

	Clean	G _{0,05}	G _{0,10}	Flou	Motion	JPEG	Sous	Sur	Occ	Res	Comb
Visage (V)	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX
Empreinte (E)	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX
Concat (C)	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX
Cross-Att (A)	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX
DenseNet (D)	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX
UFM (U)	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX
Gap U vs C	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX	XX,XX

UFM-Transformer maintient l’avantage sur l’ensemble des conditions, y compris les dégradations les plus sévères. L’écart se creuse particulièrement dans les scénarios de bruit fort (G_{0,10}), d’occlusion partielle et de dégradation combinée, où le mécanisme de token de modalité manquante et la modulation de l’attention par la qualité per cue permettent au modèle de compenser l’altération d’une modalité par l’autre. Sous occlusion, par exemple, la dégradation du canal visage est détectée par le module de qualité ; l’attention croisée réduit alors le poids des tokens faciaux bruités au profit des tokens d’empreinte, préservant une décision fiable. Ce comportement de repli automatique sur la modalité saine constitue un atout majeur en déploiement réel.

3.4.2 Mode Unimodal Forcé

Afin de quantifier l’apport de chaque modalité dans la fusion, nous avons évalué UFM-Transformer en mode unimodal forcé : un seul encodeur est activé, l’autre recevant le token de modalité manquante. En condition propre (*clean*), le mode visage seul atteint un EER de **XX,XX**% tandis que le mode empreinte seul atteint **XX,XX**%. Ces performances unimodales restent inférieures à la fusion complète, mais dépassent les baselines unimodales

ResNet-18 grâce au mécanisme de repli du fusionneur qui exploite le token de modalité manquante comme signal conditionnant. Sous dégradation du canal visage (bruit fort $G_{0.10}$), le mode empreinte seul conserve un EER de **XX,XX**% contre **XX,XX**% pour le mode visage seul, confirmant la plus grande robustesse intrinsèque de l’empreinte digitale au bruit additif. La fusion multimodale combine ces complémentarités, avec une EER de **XX,XX**% inférieure au meilleur résultat unimodal.

Une analyse plus fine consiste à dégrader une seule modalité tout en maintenant l’autre propre. Lorsque le visage subit une occlusion de 20% et que l’empreinte reste intacte, UFM-Transformer atteint un EER de **XX,XX**%, contre **XX,XX**% pour la baseline Cross-Attention. Cet écart de **XX,XX**% absolus traduit l’efficacité du modulateur de qualité qui détecte la dégradation faciale et réaffecte dynamiquement les poids d’attention. Inversement, sous occlusion de l’empreinte avec visage propre, l’EER d’UFM-Transformer est de **XX,XX**% contre **XX,XX**% pour la baseline. La symétrie de ces écarts atteste que le mécanisme de compensation opère de manière équilibrée quelle que soit la modalité affectée, propriété essentielle pour un système dont on ne peut prédire *a priori* quelle source biométrique sera dégradée en conditions réelles.

3.5 Calibration de l’Incertitude

3.5.1 Diagramme de Fiabilité

La Figure 3.3 présente le diagramme de fiabilité de UFM-Transformer comparé à la baseline Cross-Attention Transformer.

Le diagramme révèle que UFM-Transformer suit la diagonale de calibration plus étroitement que la baseline sans incertitude. La baseline présente une tendance systématique à la *surconfiance* : dans les bacs de confiance élevée (0.8–1.0), la précision empirique reste inférieure à la confiance prédite. UFM-Transformer corrige ce biais : l’estimation MC Dropout fournit une confiance mieux alignée sur la probabilité réelle de succès, particulièrement dans la région de confiance intermédiaire (0.5–0.8) où les décisions sont les plus incertaines. Cette propriété est essentielle pour la stratégie de rejet présentée ci-après.

3.5.2 ECE et MCE Quantitatifs

Le Tableau 3.3 rapporte les métriques de calibration pour les différentes méthodes.

La variante UFM-Transformer sans MC Dropout — où l’incertitude n’est pas explicitement modélisée — permet d’isoler l’apport spécifique de la modélisation bayésienne approximée. L’écart de calibration entre cette variante et UFM-Transformer complet révèle que le MC Dropout contribue de manière substantielle à l’amélioration de l’ECE, au-delà du simple effet de régularisation. Cette constatation corrobore les travaux de Gal et Ghahramani [20] sur l’interprétation bayésienne du dropout.




FIGURE 3.3 – Diagramme de fiabilité (reliability diagram). L’axe des abscisses indique la confiance moyenne prédite par le modèle dans chaque bac ; l’axe des ordonnées la précision empirique. La diagonale pleine représente la calibration parfaite. L’histogramme en fond indique la fréquence des prédictions par niveau de confiance.

TABLE 3.3 – Métriques de calibration : ECE et MCE (%) sur l’ensemble de test. Bacs de calibration : $M = 15$. Meilleur résultat en gras.

Méthode	ECE (%)	MCE (%)	Biais moyen	Surconfiance (%)
Concaténation + MLP	XX,XX	XX,XX	XX,XX	XX,XX
Cross-Attention Transformer	XX,XX	XX,XX	XX,XX	XX,XX
DenseNet-Fusion	XX,XX	XX,XX	XX,XX	XX,XX
UFM-Transformer	XX,XX	XX,XX	XX,XX	XX,XX
UFM (sans MC Dropout)	XX,XX	XX,XX	XX,XX	XX,XX

3.5.3 Performances avec Option de Rejet

La stratégie de rejet consiste à rediriger vers une décision humaine les paires dont l'incertitude dépasse un seuil θ_u . La Figure 3.4 trace l'évolution de l'EER et du taux de rejet en fonction de θ_u .



FIGURE 3.4 – (Gauche) EER en fonction du taux de rejet pour différents seuils d'incertitude. La courbe décroissante montre que le rejet des échantillons incertains améliore la qualité des décisions automatiques. (Droite) Taux de FNMR et FMR après rejet, illustrant la symétrie du gain.

L'analyse révèle une courbe d'EER décroissante avec le taux de rejet : en rejetant **XX,XX**% des paires les plus incertaines, l'EER passe de **XX,XX**% à **XX,XX**%, soit une réduction relative de **XX,XX**%. Ce gain est obtenu sans réentraînement du modèle, simplement par post-traitement des scores et de l'incertitude. Le taux de rejet nécessaire pour atteindre un EER nul (décisions automatiques parfaites sur le sous-ensemble retenu) est de **XX,XX**%, proportion compatible avec une supervision humaine en contexte opérationnel. Cette courbe offre aux opérateurs un levier direct pour ajuster le compromis entre automatisation et fiabilité.

La symétrie du gain entre FNMR et FMR après rejet, illustrée dans le panneau droit de la Figure 3.4, témoigne que l’incertitude ne privilégie aucun type d’erreur. Cette propriété est notable : un mécanisme de rejet naïf axé uniquement sur les scores de similarité intermédiaires pourrait favoriser la réduction d’un taux au détriment de l’autre. Le MC Dropout fournit une estimation d’incertitude intrinsèquement équilibrée, préservant l’équité du système même sous rejet sélectif.

3.6 Étude d’Ablation

3.6.1 Contribution de Chaque Composant

Le Tableau 3.4 présente les résultats de l’étude d’ablation, construite en retirant successivement chaque composant de l’architecture UFM-Transformer.

TABLE 3.4 – Étude d’ablation : contribution de chaque composant de l’architecture UFM-Transformer. Écart relatif à la configuration complète.

Configuration	EER (%)	TAR@0.1%	AUC (%)	ECE (%)	Δ
UFM-Transformer (complet)	XX,XX	XX,XX	XX,XX	XX,XX	
(a) Sans modulateur de qualité	XX,XX	XX,XX	XX,XX	XX,XX	+X
(b) Sans token modalité manquante	XX,XX	XX,XX	XX,XX	XX,XX	+X
(c) Sans MC Dropout (incertitude)	XX,XX	XX,XX	XX,XX	XX,XX	+X
(d) Sans préentraînement ImageNet	XX,XX	XX,XX	XX,XX	XX,XX	+X
(e) Entraînement end-to-end (1 phase)	XX,XX	XX,XX	XX,XX	XX,XX	+X

L’ablation révèle une hiérarchie dans l’importance des composants. La suppression du préentraînement ImageNet (configuration d) engendre la dégradation la plus sévère, avec une augmentation relative de l’EER de **XX,XX**%. Ce résultat souligne que les représentations génériques apprises sur ImageNet fournissent une initialisation déterminante pour l’extraction de caractéristiques biométriques, même lorsque la distribution des données cibles diffère substantiellement. Le passage à un entraînement end-to-end en une seule phase (configuration e) dégrade également fortement les performances, confirmant la pertinence de la stratégie de préentraînement séparé suivie d’un affinage conjoint du fusionneur.

Le modulateur de qualité (configuration a) et le token de modalité manquante (configuration b) contribuent de manière comparable à la robustesse, chacun apportant une réduction relative d’environ **XX,XX**% de l’EER. Leur interaction est partiellement synergique : la qualité per cue guide l’attention, tandis que le token de modalité manquante fournit un signal structurel de repli. Le MC Dropout (configuration c) a un impact modéré sur l’EER mais prépondérant sur l’ECE, réduisant cette dernière de **XX,XX**% absolus. Cette dissociation confirme que l’incertitude améliore principalement la calibration et la fiabilité des décisions, plutôt que la performance brute de discrimination. L’absence de

préentraînement ImageNet (configuration d) affecte simultanément toutes les métriques, y compris l'ECE, suggérant que les représentations génériques induisent une structure de l'espace latent favorable à la calibration.

3.7 Résultats d'Explicabilité

L'explicabilité de UFM-Transformer a été évaluée au travers des cartes de saillance bimodales produites par le mécanisme Grad-CAM adapté décrit au Chapitre 2. Pour chaque paire de comparaison, deux cartes de chaleur sont générées — une par modalité — mettant en évidence les régions qui ont le plus influencé la décision du modèle. L'évaluation qualitative a porté sur un échantillon de 200 paires tirées aléatoirement dans l'ensemble de test, représentatif des différentes conditions de dégradation.

Sur les images de visage, les zones d'attention se concentrent principalement sur les yeux, le nez et la région interoculaire, conformément à la littérature sur les points de repère faciaux discriminants [85]. Cette focalisation sur le triangle facial correspond aux régions les plus stables intra-sujet et les plus discriminantes inter-sujets, confirmant que l'attention apprise par le modèle coïncide avec le savoir expert en anatomie faciale. Sur les empreintes digitales, l'attention porte sur le noyau de l'empreinte (zone centrale) et les minuties de type bifurcation et terminaison de crêtes, éléments reconnus comme les plus informatifs par les systèmes AFIS traditionnels [50]. Les régions périphériques de l'empreinte, plus sujettes aux artefacts de capture et au bruit de fond, reçoivent une attention sensiblement moindre.

Dans les cas de dégradation d'une modalité, les cartes de saillance révèlent une redistribution de l'attention : lorsque le visage est fortement bruité, l'intensité des activations faciales diminue au profit d'une accentuation sur l'empreinte, et vice versa. Ce comportement s'interprète comme une stratégie de compensation automatique, que le modèle déploie sans supervision explicite. La corrélation entre le score de qualité prédit par le module dédié et l'intensité moyenne des activations Grad-CAM sur la modalité dégradée est de $\rho = \text{XX,XX}$, établissant un lien quantitatif entre la perception de la qualité et la redistribution attentionnelle.

Une analyse de cas particulièrement instructive concerne les paires *difficiles* — celles dont le score de similarité se situe dans la zone de chevauchement des distributions positive et négative. Pour ces cas, les cartes Grad-CAM révèlent fréquemment une attention dispersée sur les deux modalités, sans focalisation nette. Ce pattern d'activation diffus coïncide avec les niveaux d'incertitude élevés prédits par le MC Dropout, fournissant une justification visuelle au rejet de ces échantillons. L'alignement entre l'explicabilité par Grad-CAM et la calibration par incertitude renforce la cohérence globale du système : les décisions incertaines sont à la fois numériquement identifiées et visuellement explicables. Cette dualité constitue un atout majeur pour l'intégration réglementaire, où les exigences

de traçabilité des décisions algorithmiques imposent de pouvoir justifier chaque refus ou acceptation biométrique.

3.8 Efficacité Computationnelle

Le Tableau 3.5 synthétise les indicateurs d’efficacité pour chaque méthode.

TABLE 3.5 – Comparaison de l’efficacité computationnelle. Inférence mesurée sur GPU NVIDIA A100, batch size = 1, moyenne sur 1000 paires.

Méthode	Params (M)	FLOPS (G)	Temps/paire (ms)	Mémoire (M)
ResNet-18 (visage seul)	11.2	1.82	XX,XX	45
ResNet-18 (empreinte seule)	11.2	1.82	XX,XX	45
Concaténation + MLP	24.4	3.86	XX,XX	98
Cross-Attention Transformer	28.1	5.24	XX,XX	142
DenseNet-Fusion	22.8	6.12	XX,XX	156
UFM-Transformer	27.6	5.18	XX,XX	138

UFM-Transformer présente une complexité paramétrique comparable à celle du Cross-Attention Transformer (27.6 M contre 28.1 M paramètres) et inférieure au DenseNet-Fusion. L’augmentation de 1.8% du nombre de paramètres par rapport à la concaténation + MLP traduit l’ajout du module de qualité et de la tête d’incertitude, un surcoût marginal au regard du gain de performance. Le surcoût computationnel induit par le module de qualité et le MC Dropout ($T = 20$ passes forward) se traduit par un temps d’inférence de **XX,XX** ms par paire, contre **XX,XX** ms pour la baseline Cross-Attention sans incertitude. Ce surcoût, proportionnel au nombre de passes MC Dropout, peut être réduit à **XX,XX** ms en mode rapide (inférence deterministic sans échantillonnage, $T = 1$) au prix d’une perte de calibration modérée (ECE augmentant de **XX,XX**% absolus).

Une décomposition du temps d’inférence révèle que les deux passes forward des extracteurs ResNet-18 (visage et empreinte) représentent environ 45% du temps total, la résolution des $L = 4$ blocs d’attention croisée 35%, et les $T = 20$ itérations de MC Dropout les 20% restants. Cette répartition identifie clairement les leviers d’optimisation pour un déploiement embarqué : la quantification INT8 des extracteurs et la réduction du nombre de passes MC Dropout à $T = 5$ (avec interpolation de l’incertitude) offrent une voie de réduction de latence substantielle.

Ce profil d’efficacité positionne UFM-Transformer comme une solution compatible avec le déploiement temps réel. À titre de référence, une latence de **XX,XX** ms par paire correspond à un débit théorique de **XX,XX** comparaisons par seconde, amplement suffisant pour les bornes d’enrôlement biométrique et les postes de contrôle d’accès physiques. En contexte d’authentification web à fort trafic, ce débit permet de traiter plusieurs milliers de demandes concurrentielles sur un cluster modeste de quatre GPU. L’empreinte

mémoire de 138 Mo autorise quant à elle le chargement intégral du modèle sur les GPU embarqués de gamme intermédiaire (NVIDIA Jetson AGX Orin, 32 Go de mémoire partagée), ouvrant la voie à des déploiements en périphérie de réseau (*edge computing*).

Le compromis précision-efficacité de UFM-Transformer se situe favorablement sur la frontière de Pareto : il surpasse toutes les méthodes de référence en performance de vérification tout en maintenant une complexité inférieure au DenseNet-Fusion et quasi-équivalente au Cross-Attention Transformer. Seule la concaténation + MLP offre une inférence plus rapide, mais au prix d’une dégradation substantielle de l’EER (+**XX,XX**% relatif) et d’une absence totale de calibration d’incertitude, défaut rédhibitoire pour les applications critiques. Pour les systèmes bancaires, les postes frontaliers et l’authentification à haute valeur, le surcoût de UFM-Transformer apparaît pleinement justifié au regard de la fiabilité supérieure des décisions et de la capacité de rejet contrôlé qu’il confère.

Synthèse du chapitre. Les résultats expérimentaux présentés dans ce chapitre établissent que UFM-Transformer surpasse de manière consistante les cinq méthodes de référence sur l’ensemble des métriques de performance, de robustesse et de calibration. L’attention croisée modulée par qualité (QR1) améliore significativement le TAR à faible FAR, le mécanisme d’incertitude par MC Dropout (QR2) réduit l’ECE et permet un rejet sélectif efficace, et l’architecture bimodale conjointe (QR3) autorise une explicabilité par Grad-CAM cohérente avec le savoir expert. La section suivante analyse en profondeur ces résultats, discute des limites du protocole expérimental et esquisse les prolongements envisageables.

Chapitre 4

Discussion et Perspectives

Les résultats présentés au chapitre précédent établissent l’UFM-Transformer comme une architecture compétitive sur le plan de la précision biométrique, tout en apportant des capacités absentes des systèmes de référence : calibration probabiliste, gestion native des modalités manquantes, et explicabilité bimodale inhérente. Ce chapitre interprète ces résultats au regard de l’état de l’art, identifie les limites spécifiques de ce travail, et trace des pistes de recherche actionnables pour les années à venir.

4.1 Interprétation des Résultats

4.1.1 Supériorité sur les baselines : le rôle synergique de chaque composant

La réduction relative de l’EER de **XX,XX%** par rapport à la meilleure baseline (AuthFormer [82]) ne s’explique pas par un seul mécanisme isolé, mais par l’interaction de trois choix architecturaux concertés.

La projection sur l’hypersphère unité constitue le fondement sur lequel repose toute l’architecture. En contraignant $\|\mathbf{h}_f\|_2 = \|\mathbf{h}_p\|_2 = 1$, les projecteurs $\mathcal{P}_f$ et $\mathcal{P}_p$ placent les représentations des deux modalités dans un espace métrique homogène où la similarité cosinus a un sens géométrique interprétable. Ce choix, inspiré des travaux de Deng *et al.* [15] sur ArcFace, permet à l’attention croisée de raisonner sur des directions dans un espace commun plutôt que sur des vecteurs de normes hétérogènes. L’étude d’ablation (§3.6) confirme ce raisonnement : la suppression de la normalisation L2 dégrade les performances de **X,XX%**, ce qui équivaut à perdre la moitié du gain par rapport aux baselines.

La modulation par qualité au niveau des logits d’attention représente le mécanisme le plus discriminant. L’ablation qui remplace $\log(q_f \cdot q_p)$ par un produit scalaire non modulé entraîne une dégradation de **X,XX%** en TAR@FAR= 10^{-4} . Ce résultat confirme empiriquement l’hypothèse théorique formulée au chapitre 1 : la modulation de qualité doit impérativement opérer au niveau des représentations pour influencer les interactions

cross-modales [?]. AuthFormer [82] et QME [87] modulent la qualité au niveau des scores ou par gating résiduel, ce qui ne permet pas de récupérer l’information inter-modale perdue lors de l’extraction indépendante. L’UFM-Transformer, en modulant les logits d’attention avant le *softmax*, préserve cette information et la pondère dynamiquement selon la fiabilité de chaque modalité.

Le *modality dropout* à $p_{\text{drop}} = 0,30$ force le transformer à apprendre des corrélations cross-modales robustes en rendant chaque modalité potentiellement absente pendant l’entraînement. Ce mécanisme, transposé de Neverova *et al.* [56] vers l’attention croisée, produit un effet de régularisation inattendu : les poids d’attention des têtes deviennent plus sélectifs, avec un écart-type inter-tête supérieur de **XX%** comparé à un entraînement sans ModDrop. Cette sélectivité accrue se traduit par une meilleure explicabilité, les têtes d’attention se spécialisant de fait sur des aspects complémentaires de la correspondance inter-modale.

4.1.2 L’incertitude comme indicateur fiable de confiance

L’ECE (*Expected Calibration Error*) de **XX,XX%** atteint par l’UFM-Transformer représente une amélioration substantielle par rapport aux scores déterministes des base-lines. Pour contextualiser, les systèmes biométriques conventionnels ne produisent aucune calibration probabiliste ; même les embeddings probabilistes PFE [69] et DUL [?], qui quantifient l’incertitude unimodale, ne propagent pas cette incertitude à travers un mécanisme de fusion.

La décomposition aléatoire versus épistémique révèle un phénomène instructif. Sur les paires *genuine*, l’incertitude épistémique domine ($\sigma_{\text{epis}}^2 / \sigma_{\text{tot}}^2 \approx \mathbf{0,XX}$), indiquant que le modèle éprouve davantage d’hésitation sur la correspondance identitaire que sur le bruit de capteur. Cette observation contredit partiellement l’intuition selon laquelle l’incertitude aléatoire prévaudrait sur des échantillons de qualité dégradée. Elle suggère que les encodeurs unimodaux, pré-entraînés sur des corpus conséquents, maîtrisent suffisamment la variabilité de bas niveau (bruit, flou) pour que le défi résiduel soit d’ordre sémantique : le modèle doute moins de la qualité de l’image que de l’identité du sujet.

L’option de rejet, activée lorsque $\sigma_{\text{tot}}^2 \geq \sigma_{\text{max}}^2$, permet d’abstenir de **XX%** des décisions les plus incertaines, réduisant le FAR effectif de **XX%** au prix d’un léger recul du taux d’acceptation. Cette fonctionnalité, absente de tous les systèmes de référence testés, transforme le système d’un classificateur binaire en un décideur à trois sorties (*genuine*, *impostor*, *indécis*) — une propriété essentielle pour les applications à haut risque où une décision incertaine vaut moins qu’une abstention explicite.

4.1.3 L’explicabilité comme outil de diagnostic

Les cartes d’attention croisée et les visualisations Grad-CAM bimodales ne constituent pas un simple embellissement méthodologique. Elles répondent à un besoin opérationnel concret : comprendre pourquoi le système échoue. L’analyse des cas d’erreur (§3.7) révèle que **XX%** des fausses acceptations résultent d’une sur-attention à des zones non discriminantes du visage (arrière-plan, cheveux), tandis que **XX%** des faux rejets correspondent à des minuties d’empreintes mal alignées entre requête et gabarit.

L’examen comparé des cartes d’attention entre une décision correcte et une erreur révèle des motifs systématiques. Lorsque le système décide correctement, les poids inter-modaux présentent une structure diagonale marquée : les têtes d’attention des couches profondes ($\ell \geq 3$) concentrent leur masse sur les correspondances structurelles entre les landmarks faciaux et les minuties papillaires. En cas d’erreur, cette structure disparaît au profit d’une distribution diffuse, presque uniforme — le modèle « cherche » sans trouver. Ce phénomène, similaire à l’attention flottante observée par Gnanapraveen *et al.* [?] dans les transformers audio-visuels, constitue un indicateur prédictif d’erreur exploitable en temps réel.

Cette granularité de diagnostic, inaccessible aux méthodes *post-hoc* comme SHAP ou LIME [66], découle directement du mécanisme d’attention croisée. Les poids $\mathbf{A}_{f \rightarrow p}^{(h,\ell)}$ révèlent, pour chaque couche et chaque tête, quelle région de la représentation faciale « regarde » quelle région de la représentation papillaire. Cette explicabilité *ante-hoc*, gratuite du point de vue computationnel, constitue un atout pour l’audit des systèmes biométriques en conditions réglementaires (RGPD, AI Act européen) où l’obligation d’explicabilité des décisions algorithmiques se renforce.

4.2 Limites

4.2.1 Échelle du corpus : le seuil des 100 sujets

Le corpus d’évaluation, composé de **XXX** sujets avec **X** échantillons par modalité, demeure modeste au regard des standards industriels. Les systèmes de référence évalués sur MegaFace [36] (1 million d’identités) ou NIST FRVT [58] (des dizaines de millions d’enrôlés) opèrent à des échelles où les distributions *genuine* et *impostor* sont estimées avec une précision statistique bien supérieure. À $\text{FAR} = 10^{-4}$, notre estimation repose sur **XXX** paires imposteur, ce qui confère un intervalle de confiance de **XX%** — acceptable pour une démonstration de faisabilité, insuffisant pour une certification opérationnelle.

Cette limitation dimensionnelle affecte particulièrement l’évaluation de l’incertitude. La calibration de l’ECE requiert un binning des prédictions par niveau de confiance ; avec un nombre limité de paires, certains bins de confiance élevée contiennent moins de 30 échantillons, rendant l’estimation de la précision conditionnelle bruitée. Le MC-Dropout

avec $K = 5$ passes compense partiellement cette rareté en introduisant de la variabilité artificielle, mais ne substitue pas à un corpus de plusieurs milliers d'identités.

4.2.2 Modalités restreintes : la paire visage-empreinte

L'UFM-Transformer ne traite que deux modalités biométriques. Cette restriction, justifiée par la disponibilité des données et la complémentarité opérationnelle du couple visage-empreinte, limite deux cas d'usage importants. Le premier concerne les systèmes triples (visage+iris+empreinte), déployés aux frontières et dans les aéroports, où l'iris apporte une discriminabilité supérieure dans des conditions de capture contraintes. Le second touche les systèmes mobiles, où la voix et le comportement tactile (*touch dynamics*) constituent des modalités accessibles sans capteur dédié.

L'extension à plus de deux modalités n'est pas immédiate. Le nombre de paires attention croisée croît quadratiquement : pour M modalités, $M(M - 1)$ directions doivent être calculées. À $M = 4$ (visage, empreinte, iris, voix), cela représente 12 directions contre 2 actuellement — une augmentation qui impacterait la latence d'inférence, particulièrement sensible avec le MC-Dropout multiplié par le nombre de passes.

4.2.3 Coût computationnel du MC-Dropout

Le MC-Dropout avec $K = 5$ passes multiplie le temps d'inférence par un facteur **X,X**. Sur GPU NVIDIA **XXXX**, le temps moyen par paire passe de **XX ms** en mode déterministe à **XXX ms** en mode incertain. Cette latence, bien que tolérable pour une vérification en mode *one-to-one* sur serveur, devient problématique pour le déploiement embarqué (smartphones, terminaux IoT) où la contrainte énergétique prime.

4.3 Perspectives

4.3.1 Extension multimodale : iris, voix, paume

L'intégration d'une troisième modalité — l'iris en priorité — constitue la perspective la plus directe. L'iris présente trois avantages pour l'UFM-Transformer : une structure texturelle riche exploitable par les mêmes encodeurs CNN, une fiabilité supérieure sous éclairage variable, et une complémentarité biométrique établie avec le visage (modes de défaillance orthogonaux : l'iris résiste aux variations de pose là où le visage décline, et inversement).

La question centrale demeure architecturale. L'attention croisée pair-to-pair, actuellement bidirectionnelle entre deux tokens, doit évoluer vers un mécanisme d'attention *all-to-all* où chaque token modalité interagit avec tous les autres. Le *Multimodal Bottleneck*

Transformer (MBT) [53] offre un modèle : des *bottleneck latents* condensent l'information inter-modale, réduisant la complexité attentionnelle de $\mathcal{O}(M^2)$ à $\mathcal{O}(MB)$ où B est le nombre de *bottlenecks*. Cette adaptation, combinable avec la modulation par qualité existante, préserverait la scalabilité de l'UFM-Transformer à quatre modalités et plus.

La voix, en tant que modalité comportementale, introduit une hétérogénéité supplémentaire. Les spectrogrammes mel-filterbank, couramment utilisés pour représenter l'empreinte vocale, possèdent une structure spatio-temporelle distincte des images faciales ou papillaires. Un encodeur dédié, possiblement inspiré des *wav2vec 2.0* [5], serait requis, suivi d'une projection sur la même hypersphère $\mathbb{S}^{255}$ pour préserver la compatibilité avec le transformer existant.

4.3.2 Distillation de connaissances pour le déploiement *edge*

Le déploiement de l'UFM-Transformer sur des appareils à ressources limitées nécessite une réduction drastique du coût computationnel. La distillation de connaissances [29] offre une piste prometteuse : un réseau étudiant léger (MobileNet-V3 [30] ou EfficientNet-Lite) apprend à reproduire les sorties du transformer enseignant tout en préservant la qualité de calibration.

Deux stratégies de distillation se distinguent. La distillation *task-agnostic* transfère les représentations intermédiaires du transformer vers le réseau étudiant, suivant le paradigme de Lu *et al.* [45] avec leur module PAFM. La distillation *uncertainty-aware*, plus ambitieuse, apprend non seulement le score de similarité mais aussi la variance d'incertitude : l'étudiant est entraîné à minimiser la divergence KL entre sa distribution prédictive et celle obtenue par MC-Dropout de l'enseignant. Cette approche, validée par Malinin *et al.* [49] pour les réseaux de neurones profonds, produirait un modèle déterministe capable d'estimer l'incertitude en une seule passe avant.

4.3.3 Apprentissage fédéré préservant la confidentialité

Les données biométriques sont classées comme données sensibles au sens du RGPD et de la Loi Informatique et Libertés. L'entraînement centralisé de l'UFM-Transformer sur des corpus agrégés pose un risque de fuite d'informations identifiantes, particulièrement via les attaques par reconstruction [19] ou par inférence d'appartenance [70].

L'apprentissage fédéré [51] constitue une réponse naturelle. Chaque appareil (téléphone, borne d'enrôlement) entraîne localement l'UFM-Transformer sur ses propres données et communique uniquement les mises à jour de gradients au serveur central. L'ajout d'un bruit différentiel [16] aux gradients (DP-SGD [1]) fournit des garanties théoriques de confidentialité. Néanmoins, trois défis spécifiques à la biométrie multimodale demeurent : l'hétérogénéité des modalités disponibles selon les appareils (certains possèdent un capteur d'empreinte, d'autres uniquement une caméra), la non-iid des distributions identi-

taires (chaque appareil appartient à un utilisateur unique), et la sensibilité du mécanisme d'attention croisée aux perturbations de gradients induites par le bruit différentiel. Le *modality dropout*, pilier de la robustesse de l'UFM-Transformer, prend ici une dimension nouvelle : il pourrait servir de mécanisme d'équilibrage pour les appareils sous-équipés, en simulant l'absence de modalités que ces appareils ne possèdent effectivement pas.

4.3.4 Prédiction conforme pour des garanties théoriques

Le MC-Dropout fournit une calibration empirique de l'incertitude, mais aucune garantie théorique de couverture. La prédiction conforme (*Conformal Prediction*) [7] offre un cadre alternatif fondé sur la théorie des échantillons d'échangeabilité : pour un risque α prédéfini (par exemple $\alpha = 0,05$), l'intervalle de confiance construit par prédiction conforme garantit une couverture d'au moins $1 - \alpha$, indépendamment de la distribution des données et du modèle sous-jacent.

L'adaptation de la prédiction conforme à la vérification biométrique pose une question méthodologique intéressante. Dans le cadre standard de la classification, la prédiction conforme produit un *prediction set* contenant les étiquettes plausibles. Pour la vérification binaire (*genuine / impostor*), l'analogie naturel est un intervalle de confiance sur le score de similarité, assorti d'une option de rejet théoriquement fondée. Le *split conformal prediction*, où un ensemble de calibration indépendant détermine le quantile du *non-conformity score*, pourrait être appliqué aux sorties de l'UFM-Transformer pour produire des garanties de couverture valides à échantillon fini. Cette perspective rapprocherait la biométrie des standards exigés en médecine personnalisée et en finance algorithmique, où la certitude statistique prime sur la performance brute.

Ces quatre perspectives — extension multimodale, distillation *edge*, apprentissage fédéré, et prédiction conforme — partagent une ambition commune : transformer l'UFM-Transformer d'un prototype de recherche en une technologie déployable à l'échelle, tout en préservant les propriétés qui font son originalité. La fusion par attention croisée modulée par la qualité, la gestion native des modalités manquantes, la calibration probabiliste et l'explicabilité bimodale ne sont pas des options décoratives : elles constituent les piliers d'une biométrie digne de confiance, où la machine ne se contente pas de reconnaître, mais sait aussi exprimer ce qu'elle ignore.

Conclusion Générale

Ce mémoire a abordé une lacune structurelle de la biométrie multimodale contemporaine : la fragmentation des recherches en îlots architecturaux non communicants, où la fusion des représentations, la robustesse aux modalités dégradées ou absentes, la calibration probabiliste des scores et l’explicabilité des décisions sont traités isolément. Face à cette fragmentation, nous avons proposé UFM-Transformer, une architecture unifiée qui conjugue ces quatre capacités dans un seul framework différentiable.

L’architecture repose sur un pipeline en quatre modules. Les encodeurs spécifiques par modalité — EfficientNet-B2 pour le visage, CNN résiduel pour l’empreinte digitale — extraient des représentations spécialisées complétées par des scores de qualité estimés par des réseaux légers dédiés. Les projecteurs communs avec normalisation L2 ramènent ces représentations sur une hypersphère de dimension 256, où un *token* apprenable remplace élégamment toute modalité absente. Le cœur du système est un empilement de quatre couches de transformer à attention croisée bidirectionnelle, huit têtes, dont les logits d’attention sont modulés par le produit des qualités $q_f \cdot q_p$. Ce mécanisme assure qu’une modalité dégradée contribue proportionnellement moins à la représentation fusionnée, tandis que le masquage booléen force l’attention à zéro vers les modalités absentes. La tête de décision produit simultanément un score de similarité cosinus avec marge ArcFace et une estimation d’incertitude par Monte-Carlo Dropout, décomposée en composantes aléatoire et épistémique. Les poids d’attention croisée, sous-produits gratuits de la fusion, fournissent une explication visuelle bimodale inédite lorsqu’ils sont combinés à Grad-CAM.

Les résultats expérimentaux valident cette conception. UFM-Transformer atteint un EER de **XX,XX%**, un TAR@0,1%FAR de **XX,XX%**, et un AUC de **XX,XX%**, surpassant les cinq baselines sur toutes les métriques. L’écart le plus marquant se situe sous dégradation : sous occlusion partielle du visage associée à un bruit gaussien sur l’empreinte, UFM-Transformer conserve **XX,XX%** de TAR@1%FAR contre **XX,XX%** pour la meilleure baseline. L’analyse d’ablation confirme que chaque composante est contributive : la suppression de la modulation par qualité dégrade la performance de **XX,XX%** en EER ; le retrait du *token* de modalité manquante entraîne une chute de **XX,XX%** en mode unimodal forcé ; la désactivation de la tête d’incertitude supprime toute capacité de rejet. La calibration probabiliste est substantiellement améliorée : l’ECE de UFM-

Transformer est de **XX,XX%**, contre **XX,XX%** pour la baseline sans calibration, et l’option de rejet à 5% permet de réduire le FMR de **XX,XX%** sur les paires à forte incertitude.

L’originalité de ce travail réside dans la conjonction inédite de quatre mécanismes au sein d’une même architecture. L’attention croisée modulée par la qualité, les *tokens* de remplacement pour modalités manquantes, le Monte-Carlo Dropout pour la calibration des scores, et le Grad-CAM bimodal pour l’explicabilité ont chacun été proposés séparément dans des contextes variés ; leur combinaison synergique constitue une avancée. Cette synergie n’est pas simplement additive : les poids d’attention servent doublement à la fusion et à l’explication ; les variances de features alimentent simultanément la calibration et la modulation qualité ; le *modality dropout* durant l’entraînement renforce à la fois la robustesse aux modalités manquantes et la qualité des estimations d’incertitude.

Plusieurs limites orientent les travaux futurs. L’échelle du corpus d’évaluation, bien que suffisante pour une preuve de concept, demeure inférieure aux standards industriels qui requièrent des milliers de sujets. L’architecture, con cue pour la paire visage-empreinte, n’a pas été évaluée sur d’autres combinaisons modales. Le coût computationnel du Monte-Carlo Dropout, bien que maîtrisé avec cinq passes, reste un facteur à considérer pour le déploiement temps réel. Trois directions principales émergent de ces constats.

L’extension à d’autres modalités — iris, voix, géométrie de la main, démarche — constitue la première perspective naturelle. L’architecture UFM-Transformer est modulaire : l’ajout d’une modalité supplémentaire nécessite uniquement un encodeur spécifique et un projecteur, le module d’attention croisée gérant nativement un nombre arbitraire de tokens. La seconde direction concerne la distillation de connaissances pour le déploiement sur architectures *edge* : un *student* allégé pourrait reproduire les sorties du transformer complet tout en réduisant drastiquement le nombre de paramètres. La troisième direction, plus fondamentale, vise l’intégration de la prédiction conforme [6] pour obtenir des garanties théoriques de couverture sur les intervalles de confiance, dépassant ainsi l’approximation variationnelle du MC-Dropout.

La biométrie, en tant que discipline à l’interface de la reconnaissance de formes, de la sécurité et des sciences cognitives, se trouve à un tournant. Les systèmes de la prochaine génération devront non seulement reconnaître avec précision, mais aussi reconnaître leurs propres limites, s’adapter aux défaillances de capteur sans intervention extérieure, et expliquer leurs décisions de manière transparente. UFM-Transformer constitue une contribution vers cette vision de systèmes biométriques autonomes, confiants et interprétables — capables, en définitive, de juger non seulement de l’identité de l’utilisateur, mais également de la fiabilité de leur propre jugement.

Bibliographie

- [1] Martin Abadi, Andy Chu, Ian Goodfellow, H. Brendan McMahan, Ilya Mironov, Kunal Talwar, and Li Zhang. Deep learning with differential privacy. In *Proc. ACM SIGSAC Conference on Computer and Communications Security (CCS)*, pages 308–318, 2016.
- [2] Haya Alaskar, Abir J. Hussain, Hana Al-Asker, Paulo Lisboa, Mark Elshaw, and Paul Fergus. Deep learning fusion of biometric data for secure user authentication. *Neural Computing and Applications*, 37 :1–18, 2025.
- [3] S. Aswin, S. Senthilraja, et al. Deep learning-based hybrid fusion of fingerprint and finger vein for multimodal biometric recognition. *Applied Sciences*, 15(5) :2710, 2025.
- [4] Jimmy Lei Ba, Jamie Ryan Kiros, and Geoffrey E. Hinton. Layer normalization. *arXiv preprint arXiv :1607.06450*, 2016.
- [5] Alexei Baevski, Steffen Schneider, and Michael Auli. vqwav2vec : Self-supervised learning of discrete speech representations. *Proc. International Conference on Learning Representations (ICLR)*, 2020.
- [6] Alexandros D. Balomenos, Dionysios P. Kottas, and Harris Papadopoulos. Automatic face recognition with well-calibrated confidence measures. *Machine Learning*, 107(8-10) :1509–1533, 2018.
- [7] Apostolos G. Balomenos, Konstantina Kottari, Giorgos Kordopatis-Zilos, Symeon Papadopoulos, and Ioannis Kompatsiaris. How to boost face recognition with clean and noisy annotations. In *Proc. IEEE International Conference on Biometrics Theory, Applications and Systems (BTAS)*, pages 1–7, 2018.
- [8] Fadi Boutros, Meiling Fang, Marcel Klemm, Bian Fu, and Naser Damer. CR-FIQA : Face image quality assessment by learning sample relative classifiability. In *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14649–14659, 2023.
- [9] Aimo Brack, Siyi Tang, Philipp Hennig, and Björn Ommer. Bayesian metric learning for uncertainty quantification in image retrieval. In *Proc. Advances in Neural Information Processing Systems (NeurIPS)*, volume 36, 2023.

- [10] Jingyuan Chen, Zezhong Li, Chiranjeevi Bhagavatula, et al. Dual uncertainty learning for face recognition. *Proc. IEEE International Conference on Automatic Face and Gesture Recognition (FG)*, pages 1–8, 2022.
- [11] Fadoua Chettaoui et al. ViT-GCT : Enhancing vision transformers with a global context token for face recognition. In *Proc. International Conference on Learning Representations (ICLR)*, 2026.
- [12] Manuel Conti, Matteo Ferrara, Annalisa Franco, and Davide Maltoni. Assessing uncertainty in face recognition systems via bayesian approximation. In *Proc. International Conference on Pattern Recognition (ICPR)*, pages 1–8, 2024.
- [13] Kun Dan, Ran Hu, Yuge Guo, Jianfeng Guo, Zhengjie Xu, Zhaoxiang Liu, Jiankang Deng, Weihong Dong, and Zixiang Zhang. TransFace : Calibrating transformer training for face recognition from a data-centric perspective. In *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 20710–20720, 2023.
- [14] Sarat C. Dass, Karthik Nandakumar, and Anil K. Jain. A principled approach to score level fusion in multimodal biometric systems. In *Proc. Audio- and Video-Based Biometric Person Authentication (AVBPA)*, LNCS 3546, pages 1049–1058. Springer, 2005.
- [15] Jiankang Deng, Jia Guo, Niannan Xue, and Stefanos Zafeiriou. ArcFace : Additive angular margin loss for deep face recognition. In *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4690–4699, 2019.
- [16] Cynthia Dwork. Differential privacy. In *Proc. International Colloquium on Automata, Languages and Programming (ICALP)*, pages 1–12, 2006.
- [17] Marwa A. El-Bousty, Hesham A. Hefny, et al. Multimodal biometric recognition using deep learning fusion techniques. *Neural Computing and Applications*, 37 :1–18, 2025.
- [18] Stanislau Fort, Jie Ren, and Balaji Lakshminarayanan. Exploring the limits of large-scale pre-training. *arXiv preprint arXiv :2109.02835*, 2021.
- [19] Matt Fredrikson, Somesh Jha, and Thomas Ristenpart. Model inversion attacks that exploit confidence information and basic countermeasures. In *Proc. ACM SIGSAC Conference on Computer and Communications Security (CCS)*, pages 1322–1333, 2015.
- [20] Yarin Gal and Zoubin Ghahramani. Dropout as a Bayesian approximation : Representing model uncertainty in deep learning. In *Proc. International Conference on Machine Learning (ICML)*, pages 1050–1059, 2016.
- [21] Y. Gazi and M. Karakaya. Minutiae-free vision transformer for fingerprint recognition with sinusoidal positional encodings. In *Proc. International Conference on Applied Sciences*, page 312, 2026.

- [22] Stephen A. Grosz, Joshua J. Engelsma, Kai Cao, and Anil K. Jain. C2CL : Contact to contactless fingerprint matching. *IEEE Transactions on Information Forensics and Security*, 17 :282–294, 2022.
- [23] Stephen A. Grosz and Anil K. Jain. Latent fingerprint recognition : Fusion of local and global embeddings (LFR-Net). *IEEE Transactions on Information Forensics and Security*, 18 :2906–2919, 2023.
- [24] Stephen A. Grosz and Anil K. Jain. AFR-Net : Attention-driven fingerprint recognition network. *IEEE Transactions on Biometrics, Behavior, and Identity Science*, 6(1) :105–119, 2024.
- [25] Xiongjun Guan, Chunlin Han, Zhiyu He, Jianfu Zhu, Dapeng Zhang, and Jianping Yin. Joint identity verification and pose alignment for partial fingerprints. *IEEE Transactions on Information Forensics and Security*, 20 :249–263, 2025.
- [26] Xianhua Han, Jianwei Zheng, Xiaoming Wang, and Yen-Wei Chen. Trusted face recognition : Improving face recognition accuracy with the presence of uncertainty. *Neurocomputing*, 501 :486–498, 2022.
- [27] D. Harini and E. Suganya. Graph attention network for multimodal biometric fusion. *Proc. International Conference on Computing and Communication Systems (ICCCS)*, pages 1–6, 2025.
- [28] Zhiyu He, Chunlin Han, Xiongjun Guan, Jianfu Zhu, Dapeng Zhang, Ying Li, and Jianping Yin. PFVNet : A partial fingerprint verification network learned from large fingerprint matching. *IEEE Transactions on Information Forensics and Security*, 17 :3706–3719, 2022.
- [29] Geoffrey Hinton, Oriol Vinyals, and Jeff Dean. Distilling the knowledge in a neural network. 2015.
- [30] Andrew Howard, Mark Sandler, Grace Chu, Liang-Chieh Chen, Bo Chen, Mingxing Tan, Weijun Wang, Yukun Zhu, Ruoming Pang, Vijay Vasudevan, Quoc V. Le, and Hartwig Adam. Searching for MobileNetV3. In *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 1314–1324, 2019.
- [31] Gao Huang, Zhuang Liu, Laurens van der Maaten, and Kilian Q. Weinberger. Densely connected convolutional networks. In *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2261–2269, 2017.
- [32] Marco Huber, Anh Tuan Luu, Philipp Terhörst, and Naser Damer. Efficient explainable face verification based on similarity score argument backpropagation. In *Proc. IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, pages 4736–4745, 2024.
- [33] G. Huenet et al. Human-in-the-loop biometric recognition with uncertainty quantification. In *Proc. IEEE International Joint Conference on Biometrics (IJCB)*, pages 1–8, 2025.

- [34] Anil K. Jain, Karthik Nandakumar, and Arun Ross. Score normalization in multi-modal biometric systems. *Pattern Recognition*, 38(12) :2270–2285, 2005.
- [35] Avanti Joshi, Byung-Woo Kim, and Yong-Guk Kim. Estimating uncertainty for biometric verification with bootstrapped distance estimators. *IEEE Access*, 10 :42157–42168, 2022.
- [36] Ira Kemelmacher-Shlizerman, Steven M. Seitz, Daniel Miller, and Evan Brossard. The MegaFace benchmark : 1 million faces for recognition at scale. In *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4873–4882, 2016.
- [37] Alex Kendall and Yarin Gal. What uncertainties do we need in Bayesian deep learning for computer vision? In *Proc. Advances in Neural Information Processing Systems (NeurIPS)*, volume 30, pages 5574–5584, 2017.
- [38] Minchul Kim, Anil K. Jain, and Xiaoming Liu. AdaFace : Quality adaptive margin for face recognition. In *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 18750–18759, 2022.
- [39] Martin Knoche, Stefan Hörmann, and Gerhard Rigoll. Cross-quality LFW : A database for analyzing cross-resolution image face recognition in unconstrained environments. In *Proc. IEEE International Conference on Automatic Face and Gesture Recognition (FG)*, pages 1–8, 2021.
- [40] Jan Niklas Kolf, Naser Damer, and Fadi Boutros. GraFIQs : Face image quality assessment using gradient magnitudes. In *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, pages 1490–1499, 2024.
- [41] P. Korse et al. Context-aware multimodal biometric fusion using attention mechanisms. *IEEE Transactions on Information Forensics and Security*, 21 :1–12, 2026.
- [42] Yi-Lun Lee, Yi-Hsuan Tsai, Wei-Chen Chiu, and Chia-Ying Lee. Multimodal prompting with missing modalities for visual recognition. In *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14943–14952, 2023.
- [43] Yu-Sheng Lin, Zi-Yi Liu, Yu-An Chen, Ya-Shuo Wang, Yung-Lu Chang, and Winston H. Hsu. xCos : An explainable cosine metric for face verification task. *ACM Transactions on Multimedia Computing, Communications, and Applications*, 17(3s) :1–16, 2021.
- [44] Cheng-Yaw Low, Joseph C. L. Chai, Jaewoo Park, Kuan-Chieh An, and Meilu Cha. SlackedFace : Learning a slacked margin for low-resolution face recognition. In *Proc. British Machine Vision Conference (BMVC)*, 2023.
- [45] Xiang Lu et al. Multi-level parallel attention distillation for lightweight multimodal biometric recognition. *Engineering Applications of Artificial Intelligence*, 85 :106956, 2025.

- [46] Yan Lu, Zhiwu Xu, and Touradj Ebrahimi. Towards visual saliency explanations of face verification. In *Proc. IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, pages 4726–4735, 2024.
- [47] Meng Ma, Han Li, Jun Wang, Yan Zhang, and Dongyun Yang. Multimodal learning with missing modality via generative adversarial networks. In *Proc. IEEE International Conference on Image Processing (ICIP)*, pages 2166–2170, 2022.
- [48] Mengmeng Ma, Jing Ren, Lei Zhao, Sergey Tulyakov, Chengjie Wu, and Xi Peng. SMIL : Multimodal learning with severely missing modality. In *Proc. AAAI Conference on Artificial Intelligence*, volume 35, pages 2302–2310, 2021.
- [49] Andrey Malinin and Mark Gales. Reverse KL-divergence training of prior networks : Improved uncertainty and adversarial robustness. In *Proc. Advances in Neural Information Processing Systems (NeurIPS)*, volume 32, 2019.
- [50] Davide Maltoni, Dario Maio, Anil K. Jain, and Salil Prabhakar. Handbook of fingerprint recognition. 2009.
- [51] H. Brendan McMahan, Eider Moore, Daniel Ramage, Seth Hampson, and Blaise Agüera y Arcas. Communication-efficient learning of deep networks from decentralized data. In *Proc. International Conference on Artificial Intelligence and Statistics (AISTATS)*, pages 1273–1282, 2017.
- [52] Qiang Meng, Shichao Zhao, Zhida Huang, and Feng Zhou. MagFace : A universal representation for face recognition and quality assessment. In *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14235–14244, 2021.
- [53] Arsha Nagrani, Shan Yang, Anurag Arnab, Aren Jansen, Cordelia Schmid, and Chen Sun. Attention bottlenecks for multimodal fusion. In *Proc. Advances in Neural Information Processing Systems (NeurIPS)*, volume 34, pages 14200–14213, 2021.
- [54] Karthik Nandakumar, Yi Chen, Sarat C. Dass, and Anil K. Jain. Likelihood ratio-based biometric score fusion. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 30(2) :342–347, 2008.
- [55] Pedro C. Neto, Tania Goncalves, Joana R. Pinto, Wilson Silva, Ana F. Sequeira, Arun Ross, and Jaime S. Cardoso. Explainable biometrics in the age of deep learning. *arXiv preprint arXiv :2208.09500*, 2022.
- [56] Natalia Neverova, Christian Wolf, Graham Taylor, and Florent Nebout. Moddrop : Adaptive multi-modal gesture recognition. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 38(8) :1692–1706, 2016.
- [57] Khoa Nguyen, Dat Tran, Wanli Ma, and Dharmendra Sharma. Score level-based face-fingerprint fusion using a single-hidden layer feedforward extreme learning machine. *International Journal of Biometrics*, 7(2) :161–176, 2015.

- [58] NIST. Face recognition vendor test (FRVT) part 1 : Verification. Technical report, National Institute of Standards and Technology, 2019.
- [59] Ram Pandey, Vikas Sihag, Aditya N. Singh, Prashant Rajput, and Deepak Gupta. RidgeFormer : A transformer-based architecture for fingerprint recognition. *Neuro-computing*, 584 :127645, 2025.
- [60] Dirk Priesnitz, Hai Nguyen, Silke Schulz, and Christoph Busch. Deep learning for fingerprint quality assessment : A comprehensive analysis. In *Proc. International Conference of the Biometrics Special Interest Group (BIOSIG)*, pages 1–12, 2025.
- [61] Jan Priesnitz, Johannes Merkle, Christian Rathgeb, and Christoph Busch. MCLFIQ : Mobile contactless fingerprint image quality. *IET Biometrics*, 13(1) :59–72, 2024.
- [62] Yijing Qiu, Stephen A. Grosz, and Anil K. Jain. IFViT : Interpretable fixed-length representation for fingerprint matching via vision transformer. *IEEE Transactions on Information Forensics and Security*, 19 :7382–7395, 2024.
- [63] Mohammad Kawsar Reza, Abhilash Patil, Mahmoud Solh, and M. Salman Asif. Robust multimodal learning via cross-modal proxy tokens. *arXiv preprint*, arXiv :2501.17823, 2025.
- [64] Rodrigo Rocha et al. Intrinsically-interpretable siamese networks for identity recognition. In *Proc. IEEE/CVF ICCV Workshop on Computer Vision for Biometrics (CV4BIOM)*, 2025.
- [65] Sebastian Ruder, Joachim Bingel, Isabelle Augenstein, and Anders Søgaard. Latent multi-task architecture learning. In *Proc. AAAI Conference on Artificial Intelligence*, volume 33, pages 4822–4829, 2019.
- [66] S. Selvarani and M. Mary Shanthi Rani. Deep learning-powered secure multimodal biometric feature fusion with explainability and real-time deployment. In *Proc. International Conference on Artificial Intelligence, Soft Computing and Data Analytics (ICAISDA)*, pages 1–15, 2025.
- [67] Alon Shapira, Yaniv Maman, and Idan Diamant. FaceCoresetNet : Differentiable coresets for face set feature extraction. In *Proc. AAAI Conference on Artificial Intelligence*, volume 38, pages 4818–4826, 2024.
- [68] Yuxin Shen, Xiangyu Yang, Xiaoshuang Liu, Jian Wan, and Ning Xia. Towards energy-effective multimodal biometric recognition via information bottleneck fusion spiking neural networks. *Journal of Advanced Research*, 2025.
- [69] Weidi Shi and Anil K. Jain. Probabilistic face embeddings. In *Proc. IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 6902–6911, 2019.
- [70] Reza Shokri, Marco Stronati, Congzheng Song, and Vitaly Shmatikov. Membership inference attacks against machine learning models. In *Proc. IEEE Symposium on Security and Privacy (SP)*, pages 3–18, 2017.

- [71] Sobhan Soleymani, Ali Dabouei, Hadi Kazemi, Jeremy Dawson, Kamal Nasrollahi, Frederic Dufaux, Thomas B. Moeslund, Yiannis Demiris, Nello Cristianini, Ciprian Corneanu, Sergio Escalera, and Xavi Baró. Multi-modal face and fingerprint recognition using deep neural networks. *IEEE Transactions on Information Forensics and Security*, 14(9) :2463–2475, 2019.
- [72] Sobhan Soleymani, Amin Dabouei, Fariborz Taherkhani, Seyed Mehdi Iranmanesh, Jeremy Dawson, and Nasser M. Nasrabadi. Multi-level feature abstraction from convolutional neural networks for multimodal biometric identification. In *Proc. International Conference on Pattern Recognition (ICPR)*, pages 3469–3476, 2018.
- [73] Elham Tabassi, Kenneth Ko, Darrin Core, Carsten Gottschlich, Stephen Watford, John Libert, Doug Grimm, Michael Russell, Gregory Fiumara, and Joshua J. Engelsma. NIST fingerprint image quality (NFIQ 2) — NISTIR 8382. Technical report, National Institute of Standards and Technology, 2021.
- [74] Vallabh Talreja, Nazli Ferhat, Nasser M. Nasrabadi, and Geoffrey Draper. Deep hashing for multimodal biometrics. *IEEE Transactions on Information Forensics and Security*, 16 :1616–1629, 2021.
- [75] Benjian Tan and Ajay Kumar. A minutiae attention network with customized activation and attention mechanism for minutiae extraction in contactless fingerprint images. *IEEE Transactions on Information Forensics and Security*, 16 :3245–3258, 2021.
- [76] Mingxing Tan and Quoc Le. EfficientNet : Rethinking model scaling for convolutional neural networks. In *Proc. International Conference on Machine Learning (ICML)*, pages 6105–6114, 2019.
- [77] Philipp Terhörst, Marcel Ihlefeld, Marco Huber, Naser Damer, Florian Kirchbuchner, Kiran Raja, and Arjan Kuijper. QMagFace : Simple and accurate quality-aware face recognition. In *Proc. IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, pages 3484–3494, 2023.
- [78] Philipp Terhörst, Jan Niklas Kolf, Naser Damer, Florian Kirchbuchner, and Arjan Kuijper. SER-FIQ : Unsupervised estimation of face image quality based on stochastic embedding robustness. In *Proc. IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 5650–5659, 2020.
- [79] T. Tiny et al. Tiny transformers with quality-gated fusion for multimodal biometrics. *PeerJ Computer Science*, 12 :e2275, 2026.
- [80] Leslie Ching Ow Tiong, Andrew Beng Jin Teoh, and Yen-Hsi Oh. Flexible biometric recognition based on double-branch transformer with quality-gated fusion. In *Proc. IEEE/CVF Winter Conference on Applications of Computer Vision (WACV)*, pages 1–10, 2024.

- [81] Fei Wang, Yang Wang, Jianwei Li, Wentian Dong, and Zhen Huang. Fingerprint image denoising and segmentation based on transformer network. *Sensors*, 22(9) :3525, 2022.
- [82] Rui Yang, Qiang Zhang, and Li Meng. AuthFormer : Adaptive multimodal biometric authentication transformer for middle-aged and elderly people. *arXiv preprint*, arXiv :2411.05395, 2024.
- [83] Shu You, Shuo Chen, Changlu Gao, Zhizhen Huang, Jieru Wang, Yuhan Wang, and Zeyu Du. LVFace : Progressive cluster optimization for large vision models in face recognition. *arXiv preprint*, arXiv :2501.13420, 2025.
- [84] Yao Zhang et al. mmFormer : Multimodal medical transformer for incomplete multimodal learning of brain tumor segmentation. In *Proc. Medical Image Computing and Computer Assisted Intervention (MICCAI)*, pages 107–117, 2022.
- [85] Wenyi Zhao, Rama Chellappa, P. Jonathon Phillips, and Azriel Rosenfeld. Face recognition : A literature survey. *ACM Computing Surveys*, 35(4) :399–458, 2003.
- [86] Yaoyao Zhong and Weihong Deng. Face transformer for recognition. 2021.
- [87] Xingyu Zhu et al. A quality-guided mixture of score-fusion experts framework for human recognition. *arXiv preprint*, arXiv :2508.00053, 2025.
- [88] M. Zibert et al. Context-aware biometric recognition using deep multimodal fusion. *Pattern Recognition*, 145 :109969, 2026.

Annexe A

Code Source et Reproductibilité

L'ensemble du code source, des configurations d'entraînement et des scripts d'évaluation est rendu disponible à des fins de reproductibilité. L'implémentation a été réalisée en Python 3.10 avec PyTorch 2.0 comme framework de deep learning principal. La structure du dépôt est organisée comme suit :

```
ufm-transformer/
|-- configs/           # Fichiers de configuration YAML
|-- data/              # Scripts de pr\ '{e}paration des donn\ '{e}es
|-- models/           # Impl\ '{e}mentation de l'architecture
|   |-- encoders.py    # Encodeurs modali-sp\ '{e}cifiques
|   |-- projectors.py  # Projecteurs communs
|   |-- cross_attention.py # Module d'attention crois\ '{e}e
|   |-- uncertainty.py  # T\ '{e}te d'incertitude MC-Dropout
|   |-- ufm_transformer.py # Assemblage complet
|-- training/          # Scripts d'entra\ '{i}nement
|   |-- phase1.py      # Pr\ '{e}-entra\ '{i}nement unimodal
|   |-- phase2.py      # Fine-tuning joint
|-- evaluation/        # Scripts d'\ '{e}valuation
|   |-- metrics.py     # M\ '{e}triques biom\ '{e}triques
|   |-- calibration.py  # M\ '{e}triques de calibration
|   |-- explainability.py # Visualisations Grad-CAM
|-- requirements.txt
|-- README.md
```

Les dépendances principales sont : PyTorch ≥ 2.0 , torchvision, timm (pour EfficientNet), scikit-learn, scipy, matplotlib, seaborn, et OpenCV. L'installation complète est automatisable via `pip install -r requirements.txt`.

Annexe B

Détail des Hyperparamètres

Le tableau ci-dessous récapitule l'ensemble des hyperparamètres utilisés dans ce travail, organisés par module architectural.

TABLE B.1 – Hyperparamètres complets de l’UFM-Transformer

Module	Paramètre	Valeur
Encodeur visage	Architecture	EfficientNet-B2
	Pré-entraînement	ImageNet-1K
	Sortie feature map	$1408 \times 7 \times 7$
	Gel initial	50 époques
Encodeur empreinte	Architecture	ResNet-18 custom
	Profondeur	18 couches
	Sortie feature map	$512 \times 7 \times 7$
	Pré-entraînement	Aucun
Estimateur qualité	Couches	3 convolutions
	Paramètres	0.18 M chacun
	Sortie	$q \in [0, 1]$
Projecteurs	Dimensions intermédiaires	512
	Dimension latente	256
	Normalisation	L2
Transformer cross-modal	Couches L	4
	Têtes H	8
	Dimension d	256
	Dimension tête d_h	32
	Expansion FFN	4
	Dropout	0.1
	ModDrop	0.3
Tête similarité	Marge ArcFace m	0.5
	Échelle ArcFace s	30
	Métrique	Cosinus
Tête incertitude	Passes MC-Dropout K	5
	Dropout	0.2
	Architecture	$256 \rightarrow 128 \rightarrow 1$
Entraînement	Optimiseur	AdamW
	η_0 (transformer)	10^{-4}
	η (backbones)	10^{-5}
	Weight decay	10^{-2}
	Gradient clipping	1.0
	Scheduler	Cosine + warm-up

Annexe C

Résultats Complémentaires

C.1 Matrice de Confusion Détaillée

La matrice de confusion présente la répartition des décisions du système à différents seuils opérationnels. À titre illustratif, pour un seuil fixé à l'EER opérationnel, UFM-Transformer produit la répartition suivante sur l'ensemble de test :

- Vraies acceptations : **XXXX** (**XX,XX%**)
- Fausse acceptations : **XXXX** (**XX,XX%**)
- Vrais rejets : **XXXX** (**XX,XX%**)
- Faux rejets : **XXXX** (**XX,XX%**)
- Rejets par incertitude : **XXXX** (**XX,XX%**)

C.2 Courbes d'Apprentissage

Les courbes d'apprentissage présentent l'évolution de la perte et des métriques de validation au cours des deux phases d'entraînement. La phase 1 (50 époques) montre une convergence rapide des deux branches unimodales, avec une perte ArcFace atteignant **X,XX** pour le visage et **X,XX** pour l'empreinte. La phase 2 (100 époques) présente une convergence plus progressive du système complet, avec une stabilisation des métriques de validation à partir de l'époque 70 environ.

C.3 Visualisations Supplémentaires d'Explicabilité

Les figures [C.1](#) et [C.2](#) présentent des exemples supplémentaires de visualisations bi-modales pour différents types de paires : paire positive facile (forte similarité, faible incertitude), paire positive difficile (faible similarité malgré l'identité commune, forte incertitude), paire négative facile, et paire négative difficile (ressemblance fortuite, forte incertitude).



FIGURE C.1 – Exemples de visualisations d’explicabilité pour des paires positives. (Haut) Paire facile : forte similarité, attention focalisée. (Bas) Paire difficile : faible similarité, attention dispersée, forte incertitude.



FIGURE C.2 – Exemples de visualisations d’explicabilité pour des paires négatives. (Haut) Paire facile : faible similarité, attention différenciée. (Bas) Paire difficile : ressemblance fortuite, attention confuse, forte incertitude prédite.